



BỘ MÔN KHOA HỌC MÁY TÍNH
www.fit.nuce.edu.vn

HỌC MÁY

Thuật toán k láng giềng gần nhất (KNN)

Thuật toán k láng giềng gần nhất (KNN)


1. Bài toán phân lớp
2. Giới thiệu thuật toán KNN
3. Nguyên tắc chung
4. Các bước thực hiện thuật toán KNN
5. Ứng dụng thuật toán KNN

1. Bài toán phân lớp


- ❖ Supervised learning: Học cách xác định hàm $y = f(x)$ từ tập dữ liệu huấn luyện gồm $\{\{x_1, x_2, \dots, x_N\}; \{y_1, y_2, \dots, y_N\}\}$ sao cho $y_i \cong f(x_i)$ với mọi i .
 - Mỗi điểm dữ liệu có nhãn tương ứng.
- ❖ Phân đa lớp: Đầu ra y nhận giá trị một trong số các giá trị của tập các nhãn:
 - $y \in \{\text{normal}, \text{spam}\}$
 - $y \in \{\text{fake}, \text{real}\}$

Xác định đối tượng thuộc lớp nào


Class a




Class a




Class b




Class a




?



Class a



Class b



2. Giới thiệu thuật toán KNN

❖ **K-nearest neighbors (KNN)** là một trong những thuật toán đơn giản nhất trong ML, các tên gọi khác:

- Instance-based learning
- Lazy learning
- Memory-based learning

❖ **Ý tưởng chính**

- Không có giả định hàm cụ thể nào được học
- Pha học đơn giản là lưu trữ tất cả dữ liệu trong training set
- Dự đoán đầu ra của một ví dụ dựa trên việc xem xét các **hàng xóm gần nó nhất** trong tập dữ liệu huấn luyện

❖ **Vì vậy KNN được gọi là thuật toán học không tham số.**

3. Nguyên tắc chung

- Không xây dựng mô hình
- Chỉ lưu lại các mẫu huấn luyện
- Xác định nhãn cho mẫu mới dựa trên những mẫu giống mẫu mới nhất
- Gọi là học lười (lazy learning)

❖ Ý tưởng:

Tìm ra output của dữ liệu dựa trên thông tin của những dữ liệu gần nó nhất.

4. Các bước thực hiện thuật toán KNN

Bước 1: Xác định tham số K = số láng giềng gần nhất.

Bước 2: Tính khoảng cách đối tượng cần phân lớp với tất cả đối tượng cần training trong data.

Bước 3: Sắp xếp khoảng cách theo thứ tự tăng dần và xác định K láng giềng gần nhất với đối tượng cần phân lớp.

Bước 4: Lấy tất cả các lớp của K láng giềng gần nhất.

Bước 5: Dựa vào phần lớn các lớp của K để xác định lớp cho đối tượng cần phân lớp.

4.1. Các giai đoạn của thuật toán

Giai đoạn học (huấn luyện)

- Lưu các mẫu huấn luyện có dạng $\langle x, f(x) \rangle$ vào cơ sở dữ liệu

Giai đoạn phân loại

- Đầu vào: tham số k
- Với mẫu x cần phân loại:
 1. Tìm khoảng cách $d(x, x_i)$ từ x tới tất cả các mẫu x_i trong CSDL
 2. Tìm k mẫu có $d(x, x_i)$ nhỏ nhất, giả sử k mẫu đó là $x_1, x_2, \dots, x_k$
 3. Xác định nhãn phân loại $f'(x)$ là nhãn chiếm đa số trong tập $\{x_1, x_2, \dots, x_k\}$


4.2. KNN –Thảo luận về cách tính khoảng cách

- Cách tính khoảng cách giữa 2 vector:

- Mỗi cách tính khoảng cách thể hiện cách nhìn nhận về dữ liệu
- Có vô số cách tính khoảng cách
- Cách tính khoảng cách nào là tốt?

- Cách tính khoảng cách có thể sử dụng:


- Cách tính khoảng cách giữa 2 đối tượng



4.3. KNN - Ảnh hưởng của outlier

- Outlier là gì?
- KNN nhạy cảm với các điểm **outlier**, ví dụ: Các điểm dữ liệu outlier ảnh hưởng lớn đến kết quả của việc phân lớp:
 - Các điểm dữ liệu outlier có khoảng cách đến các điểm dữ liệu chuẩn rất lớn.
 - Phân bố của các điểm outlier rất khác so với các điểm dữ liệu chuẩn
 - Nhiều hoặc lỗi của dữ liệu được thể hiện trong các điểm outlier

4.4. KNN - Minh hoạ về outlier



4.5. KNN – Khắc phục outlier

Outlier removal: Có thể loại bỏ các điểm dữ liệu xa đáng kể so với điểm trung tâm (centroid) của các class so với các điểm dữ liệu khác.

Việc loại bỏ phải được thực hiện trước khi tiến hành phân lớp.

Có thể dùng chính KNN để loại bỏ outliers



Random sampling: Thay vì lớp dựa trên toàn bộ tập dữ liệu, chúng ta sẽ lấy ngẫu nhiên tập con S từ tập dữ liệu huấn luyện.

S được sử dụng để phân cụm, tập S lúc này sẽ có ít các điểm outlier hơn tập dữ liệu gốc.

5. Ứng dụng của thuật toán KNN

Nhận dạng khuôn mặt

Nhận dạng chữ viết

Nhận dạng giọng nói

Phát hiện thư rác.

...