



BỘ MÔN KHOA HỌC MÁY TÍNH
www.fit.nuce.edu.vn

HỌC MÁY

Lec 7. Thuật toán phân cụm K-Means

Bài toán phân cụm (clustering)

- Một số phương pháp phân cụm:
 - Phân cụm dựa trên phân vùng (Partition-based clustering)
 - Phân cụm thứ bậc (Hierarchical clustering)
 - Mô hình hỗn hợp (Mixture models)
 - Phân cụm sâu (Deep clustering)
 - ...
- Đánh giá chất lượng mô hình phân cụm:
 - Khoảng cách / sự khác biệt giữa hai cụm bất kỳ phải lớn. (khoảng cách giữa các cụm)
 - Chênh lệch giữa các điểm dữ liệu bên trong một cụm phải nhỏ.

Thuật toán phân cụm K-means


- K-means được giới thiệu năm 1957 bởi Lloyd
- K-means là phương pháp phổ biến nhất cho việc phân cụm, dựa trên việc phân vùng dữ liệu
- Biểu diễn dữ liệu: $D = \{x_1, x_2, \dots, x_r\}$, với x_i là vector n chiều trong không gian Euclidean.
- K-means phân cụm D thành K cụm dữ liệu:
 - Mỗi cụm dữ liệu có một trung tâm gọi là centroid.
 - K là một hằng số cho trước

Các bước trong thuật toán K-means


- *Đầu vào*: Cho tập dữ liệu D , với K là số cụm, phép đo khoảng cách giữa 2 điểm dữ liệu là $d(x,y)$
- *Khởi tạo*: Khởi tạo K điểm dữ liệu trong D làm các điểm trung tâm (centroid)
- Lặp lại các bước sau đến khi hội tụ:
 - *Bước 1*: Với mỗi điểm dữ liệu, *gán điểm dữ liệu đó vào cluster có khoảng cách đến điểm trung tâm của cluster là nhỏ nhất*.
 - *Bước 2*: Với mỗi cluster, *xác định lại điểm trung tâm* của tất cả các điểm dữ liệu được gán vào cluster đó.

K-means – Ví dụ 1


X



(A). Random selection of k centers




Iteration 1: (B). Cluster assignment




(C). Re-compute centroids


K-means – Ví dụ 1




Iteration 2: (D). Cluster assignment



(E). Re-compute centroids




Iteration 3: (F). Cluster assignment




(G). Re-compute centroids


K-means – Ví dụ 2




(a) dataset.



(b) step 1.



(c) step 2.



(d) step 3.

K-means – Điều kiện hội tụ

- Thuật toán hội tụ khi:
 - Tại 1 vòng lặp: có ít các điểm dữ liệu được gán sang cluster khác hoặc
 - Điểm trung tâm (centroid) không thay đổi nhiều hoặc
 - Giá trị hàm mất mát không thay đổi nhiều:

$$Error = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \mathbf{m}_i)^2$$

Trong đó C_i là cluster thứ i , m_i là điểm trung tâm của cluster C_i tương ứng.

K-means – Xác định trung tâm, khoảng cách

- Tính lại điểm trung tâm của cluster C_i :

$$\mathbf{m}_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$$

Trong đó $\mathbf{m}_i$ là điểm trung tâm của cluster C_i , $|C_i|$ là kích thước của C_i


- Phép đo khoảng cách:
 - Euclidean

$$d(\mathbf{x}, \mathbf{m}_i) = \|\mathbf{x} - \mathbf{m}_i\| = \sqrt{(x_1 - m_{i1})^2 + (x_2 - m_{i2})^2 + \dots + (x_n - m_{in})^2}$$

- Ngoài khoảng cách Euclidean, tùy thuộc vào từng bài toán có thể sử dụng phương pháp đo khác (cosine, manhattan...)

K-means –Thảo luận về cách tính khoảng cách



- Cách tính khoảng cách giữa 2 vector:
 - Mỗi cách tính khoảng cách thể hiện cách nhìn nhận về dữ liệu
 - Có vô số cách tính khoảng cách
 - Cách tính khoảng cách nào là tốt?
- Cách tính khoảng cách có thể sử dụng:
 - Cách tính khoảng cách giữa 2 đối tượng



K-means - Ảnh hưởng của outlier

- Outlier là gì?
- K-means nhạy cảm với các điểm **outlier**, ví dụ: Các điểm dữ liệu outlier ảnh hưởng lớn đến kết quả của việc phân cụm:
 - Các điểm dữ liệu outlier có khoảng cách đến các điểm dữ liệu chuẩn rất lớn.
 - Phân bố của các điểm outlier rất khác so với các điểm dữ liệu chuẩn
 - Nhiều hoặc lỗi của dữ liệu được thể hiện trong các điểm outlier

K-means - Minh họa về outlier




K-means – Khắc phục outlier


- **Outlier removal:** Có thể loại bỏ các điểm dữ liệu xa đáng kể so với điểm trung tâm (centroid) của các cluster so với các điểm dữ liệu khác.
 - Việc loại bỏ có thể được thực hiện trước hoặc trong khi phân cụm.
- **Random sampling:** Thay vì phân cụm toàn bộ tập dữ liệu, chúng ta sẽ lấy ngẫu nhiên tập con S từ tập dữ liệu huấn luyện.
 - S được sử dụng để phân cụm, tập S lúc này sẽ có ít các điểm outlier hơn tập dữ liệu gốc.
 - Sau khi phân cụm xong, tập dữ liệu còn lại sẽ được gán vào các cụm đã học được

Các vấn đề gặp phải của K-means


Vấn đề 1: Chất lượng của K-means phụ thuộc vào việc khởi tạo các điểm centroid



(A). Random selection of seeds (centroids)



(B). Iteration 1



(C). Iteration 2

[Liu, 2006]


Các vấn đề gặp phải của K-means

Vấn đề 1: Chất lượng của K-means phụ thuộc vào việc khởi tạo các điểm centroid


Giải pháp 1: Lặp lại nhiều lần thuật toán K-means:

- Mỗi lần chạy lại thuật toán K-means sẽ khởi tạo các điểm centroid khác nhau
- Sau quá trình học, tiến hành gộp các kết quả từ các lần chạy thành kết quả cuối cùng


Q: Gộp thế nào?



(A). Random selection of k seeds (centroids)



(B). Iteration 1



(C). Iteration 2

[Liu, 2006]

Các vấn đề gặp phải của K-means


Vấn đề 1: Chất lượng của K-means phụ thuộc vào việc khởi tạo các điểm centroid

Giải pháp 2: Thuật toán K-means++ : Để tìm ra cụm tốt nhất, chúng ta có thể lần lượt khởi tạo các điểm trung tâm từ tập D tuần tự như sau:


- Lấy ngẫu nhiên điểm centroid đầu tiên m_1
- Lấy điểm centroid tiếp theo là điểm xa nhất so với m_1
- ...
- Lấy điểm centroid thứ i (m_i) là điểm xa nhất so với $\{m_1, \dots, m_{i-1}\}$
- ...
- Bằng cách này K-means sẽ hội tụ về gần kết quả tối ưu [Arthur, D.; Vassilvitskii, 2007]

Các vấn đề gặp phải của K-means

Vấn đề 2: Khi sử dụng khoảng cách Euclidean, K-means không thể phân cụm được các dữ liệu không có dạng hình cầu (non-spherical)



(A): Two natural clusters



(B): k -means clusters

K-means – Tổng kết

- **Ưu điểm:**

- Đơn giản
- Hiệu quả trong thực tế
- Đảm bảo hội tụ trong thời gian đa thức [Manthey & Röglin, JACM, 2011]
- Linh hoạt trong việc lựa chọn phương pháp đo khoảng cách

- **Hạn chế:**

- Việc lựa chọn các tính khoảng cách cho bài toán cụ thể khó.
- Nhạy cảm với các điểm dữ liệu outlier

References

- Arthur, D.; Vassilvitskii, S. (2007). K-means++: the advantages of careful seeding. Proceedings of the 18th annual ACM-SIAM symposium on Discrete algorithms, pp. 1027–1035.
- Arthur, D., Manthey, B., & Röglin, H. (2011). Smoothed analysis of the k-means method. Journal of the ACM (JACM), 58(5), 19.
- Bottou, Léon. Online learning and stochastic approximations. On-line learning in neural networks 17 (1998).
- B. Liu. Web Data Mining: Exploring Hyperlinks, Contents, and Usage Data. Springer, 2006.
- Lloyd, S., 1982. Least squares quantization in PCM. IEEE Trans. Inform. Theory 28, 129–137. Originally as an unpublished Bell laboratories Technical Note (1957).
- Jain, A. K. (2010). Data clustering: 50 years beyond K-means. Pattern recognition letters, 31(8), 651-666.
- Machine Learning and Data Mining lecture slide - Khoat Than, School of Information and Communication Technology Hanoi University of Science and Technology

Implementation