

## Chương 2: Các Kỹ Thuật Với Đặc Trưng

Học máy 67CS1

# Mục lục

|          |                                                                 |          |
|----------|-----------------------------------------------------------------|----------|
| <b>1</b> | <b>Khái niệm về đặc trưng</b>                                   | <b>3</b> |
| 1.1      | Khái niệm về đặc trưng trong học máy                            | 3        |
| 1.2      | Đặc trưng là gì?                                                | 3        |
| 1.3      | Vai trò của đặc trưng trong học máy                             | 3        |
| 1.4      | Các bước trong quá trình xử lý đặc trưng                        | 3        |
| 1.5      | Kỹ thuật lựa chọn và khai thác đặc trưng                        | 4        |
| 1.6      | Kết luận                                                        | 4        |
| <b>2</b> | <b>Trích rút đặc trưng trên dữ liệu liên tục</b>                | <b>5</b> |
| 2.1      | Các Phương Pháp Trích Rút Đặc Trưng Trên Dữ Liệu Liên Tục       | 5        |
| 2.1.1    | Chuẩn hóa Dữ liệu (Normalization)                               | 5        |
| 2.1.2    | Đặc trưng Thống Kê (Statistical Features)                       | 5        |
| 2.1.3    | Phân phối Tần số (Frequency Distribution)                       | 6        |
| 2.1.4    | Trích rút Wavelet (Wavelet Extraction)                          | 6        |
| 2.1.5    | Trích rút Đặc trưng Phi Tuyến (Non-linear Feature Extraction)   | 6        |
| 2.1.6    | Trích rút Đặc trưng Temporal (Temporal Feature Extraction)      | 6        |
| 2.1.7    | Kết Luận                                                        | 6        |
| <b>3</b> | <b>Trích đặc trưng trên dữ liệu rời rạc</b>                     | <b>7</b> |
| 3.1      | Biện pháp thống kê cơ bản                                       | 7        |
| 3.2      | Kỹ thuật trích rút đặc trưng dựa trên tần suất                  | 7        |
| 3.3      | Kỹ thuật trích rút đặc trưng hình học                           | 7        |
| 3.4      | Kỹ thuật dựa trên thuộc tính                                    | 7        |
| 3.5      | Kỹ thuật trích rút đặc trưng nâng cao                           | 8        |
| 3.6      | Kỹ thuật dựa trên sự kết hợp                                    | 8        |
| 3.7      | Biểu diễn dưới dạng đồ thị                                      | 8        |
| 3.8      | Kết luận                                                        | 8        |
| <b>4</b> | <b>Trích đặc trưng trên dữ liệu văn bản</b>                     | <b>9</b> |
| 4.1      | Các Kỹ Thuật Trích Rút Đặc Trưng Trên Dữ Liệu Văn Bản           | 9        |
| 4.1.1    | Bag-of-Words (BoW)                                              | 9        |
| 4.1.2    | TF-IDF (Term Frequency-Inverse Document Frequency)              | 9        |
| 4.1.3    | Word Embeddings                                                 | 9        |
| 4.1.4    | N-grams                                                         | 10       |
| 4.1.5    | Phân Tích Cảm Xúc                                               | 10       |
| 4.1.6    | Mạng Nơ-ron Tích Chập (CNN) và Mạng Nơ-ron Tái Phân Nhánh (RNN) | 10       |
| 4.2      | Code ví dụ về kỹ thuật BOW                                      | 10       |

|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| 4.2.1    | Giải thích mã nguồn                                         | 11        |
| 4.2.2    | Kết quả                                                     | 11        |
| <b>5</b> | <b>Trích đặc trưng trên dữ liệu đa phương tiện</b>          | <b>12</b> |
| 5.1      | Khái niệm trích đặc trưng                                   | 12        |
| 5.2      | Các phương pháp trích đặc trưng                             | 12        |
| 5.3      | Ứng dụng của trích đặc trưng                                | 13        |
| 5.4      | Kết luận                                                    | 13        |
| <b>6</b> | <b>Trích đặc trưng trên dữ liệu tuần tự</b>                 | <b>14</b> |
| 6.1      | Trích Đặc Trưng trong Bài Toán Học Máy Trên Dữ Liệu Tuần Tự | 14        |
| 6.1.1    | Dữ Liệu Chuỗi Thời Gian                                     | 14        |
| 6.1.2    | Dữ Liệu Văn Bản                                             | 14        |
| 6.1.3    | Dữ Liệu Âm Thanh                                            | 15        |
| 6.1.4    | Kết Luận                                                    | 15        |
| <b>7</b> | <b>Chuẩn hóa đặc trưng</b>                                  | <b>16</b> |
| 7.1      | Các kỹ thuật chuẩn hóa                                      | 16        |
| 7.2      | Lợi ích của việc chuẩn hóa đặc trưng                        | 17        |
| 7.3      | Ví dụ                                                       | 17        |
| 7.3.1    | Chuẩn hóa Min-max                                           | 17        |
| 7.3.2    | Chuẩn hóa theo trung bình và độ lệch chuẩn                  | 18        |
| 7.3.3    | Kết quả                                                     | 18        |
| <b>8</b> | <b>Chọn đặc trưng</b>                                       | <b>19</b> |
| 8.1      | Các Kỹ Thuật Chọn Đặc Trưng trong Học Máy                   | 19        |
| 8.1.1    | Chọn đặc trưng dựa trên bộ lọc (Filter Methods)             | 19        |
| 8.1.2    | Chọn đặc trưng dựa trên bao gói (Wrapper Methods)           | 19        |
| 8.1.3    | Chọn đặc trưng dựa trên mô hình (Embedded Methods)          | 20        |
| 8.1.4    | Phương pháp tự động hóa (Automated Methods)                 | 20        |
| 8.2      | Kết Luận                                                    | 20        |
| <b>9</b> | <b>Hướng dẫn thực hành</b>                                  | <b>21</b> |
| 9.1      | Các nội dung thực hành                                      | 21        |
| 9.2      | Code không sử dụng thư viện                                 | 21        |
| 9.2.1    | Tải dữ liệu và xử lý dưới dạng danh sách                    | 21        |
| 9.2.2    | Xử lý dữ liệu thiếu                                         | 22        |
| 9.2.3    | Chuẩn hóa dữ liệu                                           | 23        |
| 9.2.4    | Mã hóa biến phân loại bằng One-Hot Encoding                 | 23        |
| 9.2.5    | Tạo đặc trưng mới                                           | 23        |
| 9.2.6    | Hiển thị dữ liệu đã xử lý                                   | 24        |
| 9.3      | Code sử dụng thư viện                                       | 24        |
| 9.3.1    | Nội dung                                                    | 24        |
| 9.3.2    | Import các thư viện cần thiết và tải dữ liệu                | 24        |
| 9.3.3    | Xử lý dữ liệu thiếu                                         | 25        |
| 9.3.4    | Mã hóa biến phân loại bằng One-Hot Encoding                 | 25        |
| 9.3.5    | Tạo đặc trưng mới                                           | 25        |
| 9.3.6    | Chuẩn hóa dữ liệu                                           | 26        |
| 9.3.7    | Xây dựng mô hình và đánh giá                                | 26        |

# Chương 1

## Khái niệm về đặc trưng

### 1.1 Khái niệm về đặc trưng trong học máy

Trong lĩnh vực học máy (machine learning), khái niệm “đặc trưng” (feature) hay còn gọi là “thuộc tính” (attribute) là một yếu tố quan trọng và cốt lõi để xây dựng mô hình. Đặc trưng là những xử lý ban đầu của dữ liệu được sử dụng để đào tạo mô hình học máy. Chúng đại diện cho các đặc điểm, tính chất hoặc thông tin đặc thù của dữ liệu mà mô hình cần học. Hiểu rõ và lựa chọn đúng đặc trưng có thể ảnh hưởng lớn đến hiệu suất của mô hình.

### 1.2 Đặc trưng là gì?

Đặc trưng là mỗi yếu tố đầu vào mà mô hình sử dụng để đưa ra dự đoán. Ví dụ, trong một bài toán phân loại email spam, các đặc trưng có thể là tần suất xuất hiện của một từ khóa cụ thể, độ dài của email, hoặc sự có mặt của một nhóm từ khóa nhất định.

Trong một bài toán dự báo giá nhà, các đặc trưng có thể bao gồm: diện tích, số phòng ngủ, số phòng tắm, vị trí địa lý, năm xây dựng, v.v.

### 1.3 Vai trò của đặc trưng trong học máy

1. **Đại diện cho dữ liệu:** Đặc trưng giúp mô hình hiểu và học từ dữ liệu thô.
2. **Cải thiện hiệu suất:** Việc lựa chọn và biến đổi các đặc trưng phù hợp có thể giúp mô hình hoạt động hiệu quả hơn, giảm sai số, và tăng độ chính xác.
3. **Giảm bớt phức tạp:** Các đặc trưng giúp tóm gọn thông tin quan trọng, từ đó giảm bớt số lượng biến số mà mô hình cần xử lý, làm tăng tốc độ và hiệu quả của quá trình huấn luyện.

### 1.4 Các bước trong quá trình xử lý đặc trưng

1. **Lựa chọn đặc trưng (Feature Selection):** Xác định những đặc trưng nào có ích và loại bỏ những đặc trưng không mang lại giá trị. Các kỹ thuật lựa chọn đặc trưng phổ biến bao gồm: Filter Methods, Wrapper Methods, và Embedded Methods.

2. **Khai thác đặc trưng (Feature Extraction):** Tạo ra những đặc trưng mới từ các đặc trưng đã có. Các kỹ thuật như PCA (Principal Component Analysis) và LDA (Linear Discriminant Analysis) thường được sử dụng trong bước này.
3. **Tiền xử lý đặc trưng (Feature Preprocessing):** Bao gồm các bước như chuẩn hóa (normalization), tiêu chuẩn hóa (standardization), mã hóa (encoding) và xử lý dữ liệu thiếu.

## 1.5 Kỹ thuật lựa chọn và khai thác đặc trưng

1. **Filter Methods:** Lựa chọn đặc trưng dựa trên thống kê đơn giản mà không cần đến mô hình học máy. Ví dụ: kiểm tra tỉ lệ tương quan giữa đặc trưng và nhãn.
2. **Wrapper Methods:** Sử dụng mô hình học máy để đánh giá và lựa chọn tập hợp các đặc trưng tốt nhất.
3. **Embedded Methods:** Kết hợp quá trình lựa chọn đặc trưng ngay trong quá trình xây dựng mô hình.

## 1.6 Kết luận

Đặc trưng đóng vai trò quan trọng trong quá trình xây dựng và tối ưu hóa mô hình học máy. Việc lựa chọn và xử lý đặc trưng đúng cách có thể giúp nâng cao hiệu suất của mô hình, từ đó đạt được kết quả chính xác và hiệu quả hơn. Do đó, hiểu và vận dụng tốt các khái niệm và kỹ thuật liên quan đến đặc trưng là cần thiết đối với bất kỳ ai làm việc trong lĩnh vực học máy.

## Chương 2

# Trích rút đặc trưng trên dữ liệu liên tục

## 2.1 Các Phương Pháp Trích Rút Đặc Trưng Trên Dữ Liệu Liên Tục

Trích rút đặc trưng (Feature Extraction) là một giai đoạn quan trọng trong xử lý dữ liệu và học máy, giúp giảm thiểu số lượng dữ liệu cần xử lý và giữ lại các thông tin quan trọng. Đối với dữ liệu liên tục, có nhiều phương pháp trích rút đặc trưng hiệu quả. Trong bài viết này, chúng ta sẽ khám phá một số phương pháp phổ biến.

### 2.1.1 Chuẩn hóa Dữ liệu (Normalization)

Chuẩn hóa là việc điều chỉnh các giá trị của dữ liệu để nằm trong một khoảng nhất định, thường là giữa 0 và 1. Các kỹ thuật chuẩn hóa phổ biến bao gồm:

- **Min-Max Normalization:** Đưa các giá trị về phạm vi giữa 0 và 1.
- **Z-Score Normalization:** Sử dụng giá trị trung bình và độ lệch chuẩn của dữ liệu để chuẩn hóa.

### 2.1.2 Đặc trưng Thống Kê (Statistical Features)

Sử dụng các đặc trưng thống kê để đại diện cho dữ liệu liên tục. Một số đặc trưng thống kê thông dụng gồm:

- **Trung bình (Mean):** Giá trị trung bình của các giá trị dữ liệu.
- **Độ lệch chuẩn (Standard Deviation):** Đo lường mức độ biến động của các giá trị.
- **Giá trị cực đại và cực tiểu (Max and Min):** Giá trị lớn nhất và nhỏ nhất trong tập dữ liệu.

### 2.1.3 Phân phối Tần số (Frequency Distribution)

Sử dụng các đặc trưng dựa trên phân phối tần số để khai thác thông tin từ dữ liệu liên tục. Bao gồm các phương pháp như:

- **Histogram:** Biểu đồ tần số giúp biểu thị phân bố của dữ liệu.
- **Fourier Transform:** Chuyển đổi thời gian thành miền tần số để phân tích các dao động ẩn.

### 2.1.4 Trích rút Wavelet (Wavelet Extraction)

Wavelet transform là một công cụ mạnh để giải quyết các tín hiệu phi tuyến tính và phân đoạn thời gian. Các hệ số wavelet cung cấp thông tin về cả tần số cao và tần số thấp của dữ liệu.

### 2.1.5 Trích rút Đặc trưng Phi Tuyến (Non-linear Feature Extraction)

Các phương pháp trích rút đặc trưng phi tuyến có thể giúp tìm ra các mẫu ẩn trong dữ liệu liên tục. Một số kỹ thuật phổ biến bao gồm:

- **Principal Component Analysis (PCA):** Giảm chiều dữ liệu bằng cách tìm các tổ hợp tuyến tính của các biến số với độ biến thiên lớn nhất.
- **t-Distributed Stochastic Neighbor Embedding (t-SNE):** Giảm chiều dữ liệu và tạo ra một hình ảnh dễ hiểu về dữ liệu cao chiều.

### 2.1.6 Trích rút Đặc trưng Temporal (Temporal Feature Extraction)

Khi làm việc với dữ liệu thời gian (time-series), việc trích rút các đặc trưng temporal rất quan trọng:

- **Trích rút theo khoảng thời gian (Time-frame Based Features):** Trích rút các đặc trưng trong các khoảng thời gian nhất định, như trung bình, độ lệch chuẩn, max, và min.
- **Autoregressive Features:** Sử dụng mô hình autoregressive để trích rút các thông tin phụ thuộc thời gian.

### 2.1.7 Kết Luận

Trích rút đặc trưng là một bước quan trọng trong quá trình phân tích dữ liệu liên tục. Việc sử dụng đúng phương pháp trích đặc trưng không chỉ giúp giảm thiểu số lượng dữ liệu cần xử lý mà còn cải thiện hiệu suất của các mô hình học máy. Tùy thuộc vào tính chất của dữ liệu và mục tiêu cụ thể, bạn có thể lựa chọn các phương pháp phù hợp để có được kết quả tốt nhất.

## Chương 3

# Trích đặc trưng trên dữ liệu rời rạc

Trích rút đặc trưng (feature extraction) trên dữ liệu rời rạc là một bước quan trọng trong quá trình phân tích và xử lý dữ liệu, đặc biệt trong các lĩnh vực như học máy, khai thác dữ liệu và nhận dạng mẫu. Dưới đây là một số kỹ thuật phổ biến trong việc trích đặc trưng trên dữ liệu rời rạc:

### 3.1 Biện pháp thống kê cơ bản

- **Tần suất (Frequency):** Đếm số lần xuất hiện của từng giá trị hoặc đặc trưng trong tập dữ liệu.
- **Tỷ lệ (Proportion):** Tính tỷ lệ phần trăm của các giá trị trong tập dữ liệu so với tổng số mẫu.

### 3.2 Kỹ thuật trích rút đặc trưng dựa trên tần suất

- **Bag-of-Words (BoW):** Được sử dụng phổ biến trong xử lý ngôn ngữ tự nhiên, mô hình này tạo ra một không gian đặc trưng từ tần suất xuất hiện của các từ trong văn bản.
- **Term Frequency-Inverse Document Frequency (TF-IDF):** Là một phương pháp nâng cao hơn, tính đến tần suất từ trong một tài liệu và mức độ phổ biến của từ đó trong toàn bộ tập tài liệu.

### 3.3 Kỹ thuật trích rút đặc trưng hình học

- **Xử lý ảnh:** Trong các bài toán nhận diện ảnh, các đặc trưng như điểm đặc trưng (corner points), đường viền (edges), và vùng quan tâm (regions of interest) có thể được trích xuất để phục vụ cho việc phân lớp hoặc nhận diện.

### 3.4 Kỹ thuật dựa trên thuộc tính

- **Phân loại thuộc tính (Categorical Encoding):** Các thuộc tính rời rạc có thể được mã hóa thành các giá trị số bằng cách sử dụng các phương pháp như mã hóa



nhân (Label Encoding), mã hóa one-hot (One-Hot Encoding) hay mã hóa nhị phân (Binary Encoding).

### 3.5 Kỹ thuật trích rút đặc trưng nâng cao

- **Phân tích thành phần chính (Principal Component Analysis - PCA):** Mặc dù PCA thường được sử dụng cho dữ liệu liên tục, nó cũng có thể được điều chỉnh để áp dụng cho dữ liệu rời rạc thông qua các kỹ thuật như Kernel PCA.
- **Máy vector hỗ trợ (Support Vector Machines - SVM):** SVM có thể được sử dụng cho việc trích rút đặc trưng trong các bài toán phân loại dữ liệu rời rạc.

### 3.6 Kỹ thuật dựa trên sự kết hợp

- **Mô hình kết hợp (Ensemble Methods):** Sử dụng nhiều mô hình để kết hợp các đặc trưng từ nhiều nguồn khác nhau nhằm cải thiện độ chính xác của việc dự đoán.

### 3.7 Biểu diễn dưới dạng đồ thị

- **Mạng nơ-ron:** Các mạng nơ-ron có thể học và trích xuất các đặc trưng phức tạp từ dữ liệu rời rạc thông qua việc tính chỉnh trọng số trên các tầng nơ-ron.
- **Đồ thị (Graph Features):** Trong các bài toán liên quan đến mạng xã hội hoặc dữ liệu kết nối, việc trích rút đặc trưng từ đồ thị thường liên quan đến các độ đo như bậc (degree), đường đi ngắn nhất (shortest path), v.v.

### 3.8 Kết luận

Các kỹ thuật trích rút đặc trưng trên dữ liệu rời rạc rất đa dạng và phong phú, có thể tùy chỉnh để phù hợp với từng bài toán cụ thể. Việc lựa chọn kỹ thuật phù hợp sẽ ảnh hưởng lớn đến hiệu suất của các mô hình học máy và chất lượng của các dự đoán.

# Chương 4

## Trích đặc trưng trên dữ liệu văn bản

Dưới đây là nội dung về “các kỹ thuật trích rút đặc trưng trên dữ liệu văn bản” bằng tiếng Việt:

### 4.1 Các Kỹ Thuật Trích Rút Đặc Trưng Trên Dữ Liệu Văn Bản

Trích rút đặc trưng (feature extraction) là quá trình chuyển đổi dữ liệu thành các định dạng mà từ đó có thể dễ dàng khai thác thông tin và xây dựng mô hình học máy. Trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), việc trích rút đặc trưng từ dữ liệu văn bản là rất quan trọng để phục vụ cho các tác vụ như phân loại văn bản, phân tích cảm xúc, và tìm kiếm thông tin. Dưới đây là một số kỹ thuật phổ biến:

#### 4.1.1 Bag-of-Words (BoW)

Kỹ thuật BoW biến một văn bản thành một vector đặc trưng bằng cách đếm số lần xuất hiện của từng từ trong một tập từ vựng. Mỗi văn bản sẽ được biểu diễn bằng một vector trong không gian nhiều chiều, trong đó mỗi chiều ứng với một từ trong tập từ vựng.

#### 4.1.2 TF-IDF (Term Frequency-Inverse Document Frequency)

TF-IDF là một phương pháp tinh vi hơn BoW, nhằm giảm ảnh hưởng của những từ thường gặp trong bộ văn bản (như “và”, “của”, “là”). Nó kết hợp thông tin về tần số xuất hiện của từ trong một văn bản (TF) và mức độ quan trọng của từ đó trong toàn bộ tập dữ liệu (IDF).

#### 4.1.3 Word Embeddings

Kỹ thuật này sử dụng các vector biểu diễn từ (như Word2Vec, GloVe) để nắm bắt ngữ nghĩa và mối quan hệ giữa các từ. Với các vector này, từ có thể được nhóm lại theo ý nghĩa, và điều này giúp cho các mô hình học sâu có thể nắm bắt thông tin ngữ nghĩa tốt hơn.

#### 4.1.4 N-grams

N-grams là phương pháp sử dụng các chuỗi con của  $n$  từ liên tiếp trong văn bản. Ví dụ, trong một câu, nếu  $n = 2$ , thì các bigrams sẽ là các cặp từ liên tiếp. Kỹ thuật này giúp lưu giữ thông tin ngữ cảnh tốt hơn so với việc chỉ sử dụng một từ đơn lẻ.

#### 4.1.5 Phân Tích Cảm Xúc

Các kỹ thuật như cảm xúc từ vựng (sentiment lexicon) hoặc phân tích ngữ nghĩa (semantic analysis) có thể được áp dụng để rút ra đặc trưng cảm xúc từ văn bản. Những đặc trưng này có thể giúp mô hình hiểu được thái độ hoặc cảm xúc của người viết đối với một chủ đề cụ thể.

#### 4.1.6 Mạng Nơ-ron Tích Chập (CNN) và Mạng Nơ-ron Tái Phân Nhánh (RNN)

Các mô hình học sâu như CNN và RNN có thể tự động trích rút đặc trưng từ dữ liệu văn bản mà không cần sự can thiệp của con người. Các kỹ thuật này thường được áp dụng cho các tác vụ như phân loại văn bản hoặc dịch máy.

### 4.2 Code ví dụ về kỹ thuật BOW

Dưới đây là một ví dụ về cách sử dụng kỹ thuật Bag of Words (BOW) trong Python. Phương pháp BOW là một trong những cách đơn giản và phổ biến để chuyển đổi văn bản thành tập hợp các đặc trưng số. Trong ví dụ này, chúng ta sẽ sử dụng thư viện sklearn để thực hiện.

```
# Bước 1: Cài đặt thư viện cần thiết
# Nếu bạn chưa cài đặt sklearn, bạn có thể sử dụng lệnh sau trong
# terminal:
# pip install scikit-learn

# Bước 2: Nhập các thư viện cần thiết
from sklearn.feature_extraction.text import CountVectorizer

# Bước 3: Tạo một danh sách các tài liệu (văn bản)
documents = [
    "Toi yeu hoc may.",
    "Hoc may rat thu vi.",
    "Toi muon hoc cac ky thuat moi."
]

# Bước 4: Khởi tạo CountVectorizer
vectorizer = CountVectorizer()

# Bước 5: Chuyển đổi danh sách tài liệu thành ma trận BOW
X = vectorizer.fit_transform(documents)

# Bước 6: Hiển thị ma trận BOW
```

```
print("Ma tran Bag of Words:")
print(X.toarray())

# Bước 7: Hiển thị các từ đi kèm với vị trí trong ma trận
print("Tu dien:")
print(vectorizer.get_feature_names_out())
```

### 4.2.1 Giải thích mã nguồn

- **CountVectorizer:** Đây là lớp từ thư viện sklearn giúp chuyển đổi văn bản thành dạng ma trận BOW.
- **fit\_transform:** Phương thức này thực hiện hai công việc: nó học tập từ các văn bản (fit) và sau đó chuyển đổi văn bản thành ma trận (transform).
- **toarray():** Chuyển đổi ma trận dạng sparse thành mảng NumPy để dễ dàng hiển thị.

### 4.2.2 Kết quả

- Ma trận BOW sẽ hiển thị dưới dạng bảng, trong đó mỗi hàng đại diện cho một tài liệu và mỗi cột tương ứng với một từ trong từ điển, với giá trị là số lần xuất hiện của từ trong tài liệu.
- Từ điển sẽ cho biết các từ đã được xác định và vị trí của chúng trong ma trận.

Hy vọng ví dụ trên sẽ giúp bạn hiểu rõ hơn về kỹ thuật BOW trong Python!

# Chương 5

## Trích đặc trưng trên dữ liệu đa phương tiện

Trích đặc trưng (feature extraction) trên dữ liệu đa phương tiện là một quá trình quan trọng trong lĩnh vực học máy và xử lý dữ liệu. Dữ liệu đa phương tiện thường bao gồm hình ảnh, âm thanh, video và văn bản, và việc nhận diện các đặc trưng có thể giúp cải thiện hiệu suất của các hệ thống phân tích và nhận diện thông tin.

### 5.1 Khái niệm trích đặc trưng

Trích đặc trưng là quá trình chọn lọc và biến đổi dữ liệu thô thành một định dạng dễ xử lý hơn, giúp cho các mô hình máy học có thể dễ dàng học hỏi và rút ra kết luận từ đó. Đặc trưng có thể là các thông tin quan trọng như màu sắc, hình dạng trong hình ảnh, tần số trong âm thanh, hoặc từ khóa trong văn bản.

### 5.2 Các phương pháp trích đặc trưng

- **Đối với hình ảnh:**

- **SIFT (Scale-Invariant Feature Transform):** Tìm các đặc trưng quan trọng trong hình ảnh có thể nhận diện được ở các tỉ lệ khác nhau.
- **HOG (Histogram of Oriented Gradients):** Mô tả hình dạng và cấu trúc dựa trên hướng gradient của pixel trong một hình ảnh.
- **CNN (Convolutional Neural Networks):** Mạng nơ-ron tích chập được sử dụng để tự động trích xuất đặc trưng từ các khối hình ảnh.

- **Đối với âm thanh:**

- **MFCC (Mel Frequency Cepstral Coefficients):** Thường được sử dụng trong nhận diện giọng nói, là một cách để mô tả âm thanh bằng cách phân tích tần số.
- **Spectrogram:** Biểu diễn âm thanh theo thời gian và tần số, giúp nhận diện các đặc trưng âm thanh khác nhau.

- **Đối với video:**

- **Optical Flow:** Phân tích chuyển động giữa các khung hình để trích xuất thông tin về động thái.
- **2D/3D Convolutional Networks:** Mạng nơ-ron cho việc nhận diện các mẫu hành động trong video.
- **Đối với văn bản:**
  - **Bag of Words:** Một cách đơn giản để đại diện cho văn bản dưới dạng tập hợp các từ xuất hiện, không quan tâm đến thứ tự.
  - **TF-IDF (Term Frequency-Inverse Document Frequency):** Đo lường tầm quan trọng của từ trong tài liệu so với tập tài liệu tổng thể.

### 5.3 Ứng dụng của trích đặc trưng

Trích đặc trưng trên dữ liệu đa phương tiện có thể được áp dụng trong nhiều lĩnh vực, bao gồm:

- Nhận diện khuôn mặt trong hệ thống an ninh.
- Tìm kiếm hình ảnh và video dựa trên nội dung.
- Phân tích cảm xúc từ giọng nói trong dịch vụ khách hàng.
- Tự động phân loại và gán nhãn cho tài liệu văn bản.

### 5.4 Kết luận

Quá trình trích đặc trưng là rất quan trọng để phát triển các hệ thống thông minh có khả năng tự động xử lý dữ liệu đa phương tiện. Việc lựa chọn các phương pháp trích xuất đặc trưng phù hợp có thể quyết định hiệu suất của mô hình học máy và giúp tạo ra các giải pháp hữu ích cho nhiều vấn đề trong cuộc sống hàng ngày.

# Chương 6

## Trích đặc trưng trên dữ liệu tuần tự

### 6.1 Trích Đặc Trưng trong Bài Toán Học Máy Trên Dữ Liệu Tuần Tự

Trong lĩnh vực học máy, việc xử lý và phân tích dữ liệu tuần tự như chuỗi thời gian, văn bản, và âm thanh là một thách thức lớn. Để xây dựng các mô hình hiệu quả, việc trích đặc trưng từ dữ liệu tuần tự là một bước cực kỳ quan trọng. Dưới đây là một số phương pháp phổ biến dùng để trích đặc trưng từ các loại dữ liệu này.

#### 6.1.1 Dữ Liệu Chuỗi Thời Gian

##### Các Thống Kê Cơ Bản

- **Giá trị trung bình:** Đo lường mức giá trị trung bình của chuỗi thời gian.
- **Phương sai và độ lệch chuẩn:** Đánh giá độ phân tán của dữ liệu.
- **Các giá trị cực đại và cực tiểu:** Xác định các giá trị đặc trưng như cao nhất và thấp nhất trong chuỗi.

##### Các Đặc Trưng Dựa Trên Miền Tần Số

- **Biến đổi Fourier:** Dùng để chuyển đổi dữ liệu từ miền thời gian sang miền tần số, giúp phân tích các thành phần dao động.
- **Biến đổi Wavelet:** Phân tích dữ liệu ở nhiều thang đo khác nhau, hữu ích cho việc phát hiện các đặc điểm tạm thời và cục bộ.

#### 6.1.2 Dữ Liệu Văn Bản

##### Các Kỹ Thuật Truyền Thống

- **Bag-of-Words (BOW):** Mỗi tài liệu được biểu diễn dưới dạng một vector, với mỗi phần tử đại diện cho số lần xuất hiện của từ tương ứng.
- **Term Frequency-Inverse Document Frequency (TF-IDF):** Một kỹ thuật để đánh giá tầm quan trọng của một từ trong văn bản, so với toàn bộ tập dữ liệu.

## Các Kỹ Thuật Hiện Đại

- **Word Embeddings:** Sử dụng các mô hình như Word2Vec, GloVe để biểu diễn từ dưới dạng vector trong không gian nhiều chiều.
- **Sentence Embeddings:** Biểu diễn toàn bộ câu hoặc đoạn văn bản bằng cách sử dụng các mô hình như BERT, GPT.

### 6.1.3 Dữ Liệu Âm Thanh

#### Các Đặc Trưng Cơ Bản

- **Mel-Frequency Cepstral Coefficients (MFCC):** Một trong những đặc trưng phổ biến để biểu diễn đặc tính của âm thanh trong miền tần số.
- **Spectrograms:** Biểu diễn tín hiệu âm thanh trong miền thời gian-tần số, giúp phân tích các thành phần tần số theo thời gian.

#### Các Phương Pháp Phân Tích Nâng Cao

- **Chromagram:** Biểu diễn và phân tích các nốt nhạc và các hàm phổ tương ứng.
- **ZCR (Zero-Crossing Rate):** Tần suất mà tín hiệu âm thanh đổi dấu, giúp xác định độ ồn của âm thanh.

### 6.1.4 Kết Luận

Việc trích đặc trưng từ dữ liệu tuần tự là bước then chốt trong xây dựng các mô hình học máy hiệu quả. Mỗi loại dữ liệu đòi hỏi những phương pháp riêng biệt để đảm bảo khai thác tối đa thông tin từ dữ liệu. Bằng cách sử dụng các kỹ thuật thích hợp, chúng ta có thể nâng cao hiệu quả và độ chính xác của các mô hình học máy trong việc dự đoán và phân loại dữ liệu tuần tự.



# Chương 7

## Chuẩn hóa đặc trưng

Chuẩn hóa đặc trưng (hay còn gọi là “feature normalization”) là một bước quan trọng trong quá trình tiền xử lý dữ liệu trong học máy (machine learning). Việc chuẩn hóa giúp cải thiện hiệu suất của các thuật toán học máy bằng cách đảm bảo rằng các đặc trưng (features) có mặt trong dữ liệu đều ở cùng một quy mô và dạng phân phối. Dưới đây là một số kỹ thuật chuẩn hóa đặc trưng phổ biến:

### 7.1 Các kỹ thuật chuẩn hóa

#### 1. Chuẩn hóa Min-Max:

- Phương pháp này biến đổi các giá trị đặc trưng về khoảng  $[0, 1]$  bằng công thức:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- Trong đó  $X$  là giá trị gốc,  $X_{min}$  và  $X_{max}$  lần lượt là giá trị nhỏ nhất và lớn nhất trong đặc trưng.

#### 2. Chuẩn hóa Z-score (Chuẩn hóa theo trung bình và độ lệch chuẩn):

- Phương pháp này biến đổi các giá trị đặc trưng sao cho phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1:

$$X' = \frac{X - \mu}{\sigma}$$

- Trong đó  $\mu$  là trung bình tổng thể và  $\sigma$  là độ lệch chuẩn.

#### 3. Chuẩn hóa Robust:

- Kỹ thuật này sử dụng giá trị trung vị và khoảng IQR (Interquartile Range) để loại bỏ ảnh hưởng của các giá trị ngoại lai (outliers):

$$X' = \frac{X - \text{median}(X)}{IQR(X)}$$

- Phương pháp này thường được sử dụng khi dữ liệu có nhiều giá trị ngoại lai.

#### 4. Chuẩn hóa Logarithmic:

- Sử dụng hàm log để giảm độ lớn của các giá trị đặc trưng, thường áp dụng cho các dữ liệu có phân phối không đối xứng:

$$X' = \log(X + 1)$$

- Phương pháp này giúp làm giảm sự ảnh hưởng của các giá trị lớn.

#### 5. Chuẩn hóa đối với dữ liệu nhị phân:

- Đối với các đặc trưng nhị phân (0 và 1), thường không cần phải chuẩn hóa. Tuy nhiên, nếu dữ liệu chứa một số giá trị không nổi bật, ta có thể sử dụng kỹ thuật mã hóa nhúng (embedding) hoặc tỷ lệ hóa đặc trưng.

## 7.2 Lợi ích của việc chuẩn hóa đặc trưng

- Giúp tăng tốc độ hội tụ của các thuật toán tối ưu như Gradient Descent.
- Cải thiện hiệu suất của các mô hình có trọng số như hồi quy logistic hay Support Vector Machine (SVM).
- Giảm nguy cơ overfitting cho các mô hình phức tạp.

Dưới đây là một ví dụ về chuẩn hóa dữ liệu trong Python bằng hai phương pháp: chuẩn hóa Min-max và chuẩn hóa theo trung bình và độ lệch chuẩn.

## 7.3 Ví dụ

### 7.3.1 Chuẩn hóa Min-max

Chuẩn hóa Min-max sẽ biến đổi giá trị của từng đặc trưng sao cho chúng nằm trong khoảng  $[0, 1]$ . Công thức chuẩn hóa Min-max như sau:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Trong đó:

- $X$  là giá trị gốc.
- $X_{min}$  là giá trị nhỏ nhất trong đặc trưng.
- $X_{max}$  là giá trị lớn nhất trong đặc trưng.

Dưới đây là mã Python để thực hiện chuẩn hóa Min-max:

```
import numpy as np
import pandas as pd

# Tạo một DataFrame mẫu
data = {
```

```

    'Gia tri': [10, 20, 30, 40, 50]
}
df = pd.DataFrame(data)

# Chuan hoa Min-max
df['Gia tri_MinMax'] = (df['Gia tri'] - df['Gia tri'].min()) / (df
    ['Gia tri'].max() - df['Gia tri'].min())

print("Du lieu sau khi chuan hoa Min-max:")
print(df)

```

### 7.3.2 Chuẩn hóa theo trung bình và độ lệch chuẩn

Chuẩn hóa theo trung bình và độ lệch chuẩn (Z-score normalization) sẽ biến đổi giá trị của từng đặc trưng sao cho có trung bình bằng 0 và độ lệch chuẩn bằng 1. Công thức chuẩn hóa như sau:

$$Z = \frac{X - \mu}{\sigma}$$

Trong đó:

- $\mu$  là trung bình của đặc trưng.
- $\sigma$  là độ lệch chuẩn của đặc trưng.

Dưới đây là mã Python để thực hiện chuẩn hóa theo trung bình và độ lệch chuẩn:

```

# Chuan hoa theo trung binh va do lech chuan
df['Gia tri_Zscore'] = (df['Gia tri'] - df['Gia tri'].mean()) / df
    ['Gia tri'].std()

print("Du lieu sau khi chuan hoa theo trung binh va do lech chuan:
    ")
print(df)

```

### 7.3.3 Kết quả

Khi chạy đoạn mã trên, bạn sẽ thấy một DataFrame mới có các cột giá trị đã được chuẩn hóa theo hai phương pháp khác nhau. Phép chuẩn hóa này rất hữu ích trong các bài toán học máy, giúp cải thiện hiệu suất và độ chính xác của mô hình.

# Chương 8

## Chọn đặc trưng

### 8.1 Các Kỹ Thuật Chọn Đặc Trưng trong Học Máy

Chọn đặc trưng (feature selection) là một bước quan trọng trong quy trình phát triển mô hình học máy. Quy trình này giúp cải thiện độ chính xác của mô hình, giảm thời gian huấn luyện, và làm giảm độ phức tạp của mô hình. Dưới đây là một số kỹ thuật chọn đặc trưng phổ biến trong học máy.

#### 8.1.1 Chọn đặc trưng dựa trên bộ lọc (Filter Methods)

Phương pháp này sử dụng các tiêu chí thống kê để đánh giá và chọn lọc các đặc trưng trước khi huấn luyện mô hình. Một số kỹ thuật phổ biến bao gồm:

- **Phân tích tương quan:** Sử dụng hệ số tương quan Pearson hoặc Spearman để đo lường mối tương quan giữa các đặc trưng và biến mục tiêu.
- **Kiểm định t:** Đánh giá sự khác biệt giữa các nhóm bằng cách sử dụng kiểm định t để xem đặc trưng nào có sự khác biệt rõ ràng giữa các lớp.
- **Chỉ số Chi-squared:** Thường được sử dụng trong các bài toán phân loại để đánh giá mối liên hệ giữa các đặc trưng rời rạc và biến mục tiêu.

#### 8.1.2 Chọn đặc trưng dựa trên bao gói (Wrapper Methods)

Kỹ thuật này sử dụng một mô hình học máy cụ thể để đánh giá hiệu suất của các tập đặc trưng khác nhau. Một số phương pháp bao gói phổ biến bao gồm:

- **Giảm dần (Backward Elimination):** Bắt đầu với tất cả các đặc trưng, sau đó loại bỏ từng đặc trưng không có ý nghĩa cho đến khi không còn đặc trưng nào có thể loại bỏ mà không làm giảm hiệu suất.
- **Tăng dần (Forward Selection):** Bắt đầu với tập đặc trưng rỗng và thêm từng đặc trưng vào mô hình cho đến khi không còn đặc trưng nào có thể thêm mà không làm cải thiện hiệu suất.
- **Kết hợp (Recursive Feature Elimination - RFE):** Một phương pháp kết hợp, trong đó mô hình được huấn luyện nhiều lần và loại bỏ các đặc trưng kém hiệu quả ở mỗi bước.

### 8.1.3 Chọn đặc trưng dựa trên mô hình (Embedded Methods)

Các phương pháp này kết hợp việc chọn đặc trưng ngay trong quá trình huấn luyện mô hình. Một số kỹ thuật nổi bật bao gồm:

- **Regularization:** Sử dụng các thuật toán như Lasso (L1 Regularization) và Ridge (L2 Regularization) để ưu tiên các đặc trưng có ảnh hưởng lớn trong khi giảm tầm quan trọng của các đặc trưng ít có giá trị.
- **Cây quyết định (Decision Trees):** Các mô hình như Random Forest và Gradient Boosting có thể xác định tầm quan trọng của các đặc trưng trong mô hình của chúng.

### 8.1.4 Phương pháp tự động hóa (Automated Methods)

Với sự phát triển của học máy, nhiều phương pháp tự động hóa đã được giới thiệu như AutoML. Những công cụ này có thể tự động thực hiện việc chọn đặc trưng thông qua các thuật toán khác nhau và tối ưu hóa quy trình.

## 8.2 Kết Luận

Việc chọn đặc trưng phù hợp là rất quan trọng trong học máy, vì nó có thể ảnh hưởng lớn đến hiệu suất của mô hình. Các kỹ thuật khác nhau có những ưu và nhược điểm riêng, do đó việc thử nghiệm và lựa chọn phương pháp phù hợp với dữ liệu và bài toán cụ thể là rất cần thiết.

# Chương 9

## Hướng dẫn thực hành

Sử dụng tập dữ liệu tại: [Kaggle](#) ← Bấm vào link

### 9.1 Các nội dung thực hành

1. **Tải dữ liệu:** Dữ liệu Titanic được tải từ file CSV và lưu trữ dưới dạng danh sách.
2. **Xử lý dữ liệu thiếu:** Các giá trị thiếu trong cột Age được thay thế bằng giá trị trung bình, và các giá trị thiếu trong cột Embarked được thay thế bằng giá trị phổ biến nhất.
3. **Chuẩn hóa dữ liệu:** Các cột số (Age, Fare) được chuẩn hóa theo z-score.
4. **Mã hóa biến phân loại:** Các biến phân loại (Sex, Embarked) được chuyển đổi thành các cột số bằng One-Hot Encoding.
5. **Tạo đặc trưng mới:** Một đặc trưng mới FamilySize được tạo ra bằng cách cộng SibSp, Parch và thêm 1.

### 9.2 Code không sử dụng thư viện

#### 9.2.1 Tải dữ liệu và xử lý dưới dạng danh sách

```
import csv
import math

# Tải dữ liệu Titanic từ file CSV
def load_data(file_path):
    with open(file_path, 'r') as file:
        reader = csv.reader(file)
        data = list(reader)
    return data

# Lấy dữ liệu Titanic
data = load_data('titanic.csv')

# Tách tiêu đề và dữ liệu
```

```

header = data[0]
data = data[1:]

# Hien thi du lieu mau
for i in range(5):
    print(data[i])

```

## 9.2.2 Xử lý dữ liệu thiếu

```

def fill_missing_age(data, age_index):
    # Tinh toan tuoi trung binh (bo qua cac gia tri thieu)
    total_age = 0
    count = 0

    for row in data:
        if row[age_index] != '':
            total_age += float(row[age_index])
            count += 1

    average_age = total_age / count

    # Dien gia tri thieu bang tuoi trung binh
    for row in data:
        if row[age_index] == '':
            row[age_index] = average_age

def fill_missing_embarked(data, embarked_index):
    # Tinh gia tri pho bien nhat (mode)
    embarked_counts = {}

    for row in data:
        if row[embarked_index] in embarked_counts:
            embarked_counts[row[embarked_index]] += 1
        else:
            embarked_counts[row[embarked_index]] = 1

    mode_embarked = max(embarked_counts, key=embarked_counts.get)

    # Dien gia tri thieu bang gia tri mode
    for row in data:
        if row[embarked_index] == '':
            row[embarked_index] = mode_embarked

# Xu ly du lieu thieu
age_index = header.index('Age')
embarked_index = header.index('Embarked')

fill_missing_age(data, age_index)
fill_missing_embarked(data, embarked_index)

```

### 9.2.3 Chuẩn hóa dữ liệu

```
def standardize_column(data, index):
    # Tính toán trung bình và độ lệch chuẩn
    values = [float(row[index]) for row in data]
    mean = sum(values) / len(values)
    std_dev = math.sqrt(sum([(x - mean) ** 2 for x in values]) /
                          len(values))

    # Chuẩn hóa dữ liệu
    for row in data:
        row[index] = (float(row[index]) - mean) / std_dev

# Chuẩn hóa cột 'Age' và 'Fare'
fare_index = header.index('Fare')
standardize_column(data, age_index)
standardize_column(data, fare_index)
```

### 9.2.4 Mã hóa biến phân loại bằng One-Hot Encoding

```
def one_hot_encode(data, index):
    # Lấy các giá trị duy nhất trong cột
    unique_values = list(set(row[index] for row in data))

    # Tạo các cột mới cho mỗi giá trị
    for value in unique_values:
        header.append(f"{header[index]}_{value}")

    for row in data:
        # Thêm 1 hoặc 0 cho các cột mới
        for value in unique_values:
            row.append(1 if row[index] == value else 0)

    # Xóa cột ban đầu
    for row in data:
        row.pop(index)
        header.pop(index)

# Mã hóa cột 'Sex' và 'Embarked'
sex_index = header.index('Sex')
embarked_index = header.index('Embarked')

one_hot_encode(data, sex_index)
one_hot_encode(data, embarked_index)
```

### 9.2.5 Tạo đặc trưng mới

```
def create_family_size(data, sibsp_index, parch_index):
    header.append('FamilySize')
```



```

    for row in data:
        family_size = int(row[sibsp_index]) + int(row[parch_index
]) + 1
        row.append(family_size)

# Tạo đặc trưng mới 'FamilySize' từ 'SibSp' và 'Parch'
sibsp_index = header.index('SibSp')
parch_index = header.index('Parch')

create_family_size(data, sibsp_index, parch_index)

```

## 9.2.6 Hiển thị dữ liệu đã xử lý

```

# Hiển thị tiêu đề và một số dòng dữ liệu đã xử lý
print(header)
for i in range(5):
    print(data[i])

```

## 9.3 Code sử dụng thư viện

### 9.3.1 Nội dung

- **Xử lý dữ liệu thiếu:** Giá trị thiếu trong cột Age được điền bằng giá trị trung bình và giá trị thiếu trong cột Embarked được điền bằng giá trị phổ biến nhất.
- **Mã hóa biến phân loại:** Các biến phân loại Sex và Embarked được chuyển đổi thành các biến số nhị phân sử dụng One-Hot Encoding.
- **Tạo đặc trưng mới:** Tạo các đặc trưng FamilySize và IsAlone để cung cấp thêm thông tin cho mô hình.
- **Chuẩn hóa dữ liệu:** Các cột số (Age, Fare, FamilySize) được chuẩn hóa bằng StandardScaler.

Dưới đây là ví dụ về cách tiền xử lý dữ liệu Titanic bằng Python sử dụng các thư viện phổ biến như Pandas, NumPy, và Scikit-learn. Mã nguồn này sẽ bao gồm các bước xử lý dữ liệu thiếu, mã hóa biến phân loại, tạo đặc trưng mới, và chuẩn hóa dữ liệu.

### 9.3.2 Import các thư viện cần thiết và tải dữ liệu

```

import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score

```

```
# Tải dữ liệu Titanic từ file CSV
url = 'https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv'
df = pd.read_csv(url)

# Hiển thị thông tin sơ lược về dữ liệu
print(df.head())
print(df.info())
```

### 9.3.3 Xử lý dữ liệu thiếu

```
# Điền giá trị thiếu trong cột 'Age' bằng giá trị trung bình
df['Age'].fillna(df['Age'].mean(), inplace=True)

# Điền giá trị thiếu trong cột 'Embarked' bằng giá trị phổ biến nhất
df['Embarked'].fillna(df['Embarked'].mode()[0], inplace=True)

# Xóa cột 'Cabin' vì có quá nhiều giá trị thiếu
df.drop(columns=['Cabin'], inplace=True)

# Xác nhận rằng các giá trị thiếu đã được xử lý
print(df.isnull().sum())
```

### 9.3.4 Mã hóa biến phân loại bằng One-Hot Encoding

```
# Mã hóa các biến phân loại 'Sex' và 'Embarked'
df = pd.get_dummies(df, columns=['Sex', 'Embarked'], drop_first=True)

# Hiển thị dữ liệu sau khi mã hóa
print(df.head())
```

### 9.3.5 Tạo đặc trưng mới

```
# Tạo đặc trưng mới 'FamilySize' từ 'SibSp' và 'Parch'
df['FamilySize'] = df['SibSp'] + df['Parch'] + 1

# Tạo đặc trưng 'IsAlone': 1 nếu hành khách đi một mình, ngược lại là 0
df['IsAlone'] = 1 # Mặc định là đi một mình
df['IsAlone'].loc[df['FamilySize'] > 1] = 0

# Xóa các cột không cần thiết như 'PassengerId', 'Name', 'Ticket'
df.drop(columns=['PassengerId', 'Name', 'Ticket'], inplace=True)

# Hiển thị dữ liệu sau khi tạo đặc trưng mới
```

```
print(df.head())
```

### 9.3.6 Chuẩn hóa dữ liệu

```
# Xác định các cột cần chuẩn hóa
numerical_features = ['Age', 'Fare', 'FamilySize']

# Sử dụng StandardScaler để chuẩn hóa dữ liệu
scaler = StandardScaler()
df[numerical_features] = scaler.fit_transform(df[
    numerical_features])

# Hiển thị dữ liệu sau khi chuẩn hóa
print(df.head())
```

### 9.3.7 Xây dựng mô hình và đánh giá

```
# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X = df.drop(columns=['Survived'])
y = df['Survived']

X_train, X_test, y_train, y_test = train_test_split(X, y,
    test_size=0.2, random_state=42)

# Sử dụng mô hình RandomForest để huấn luyện
model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

# Dự đoán và đánh giá mô hình
y_pred = model.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)

print(f"Accuracy of the model: {accuracy * 100:.2f}%")
```

Mã nguồn trên sử dụng các thư viện như Pandas, NumPy, và Scikit-learn để thực hiện toàn bộ quy trình tiền xử lý dữ liệu và xây dựng mô hình một cách dễ dàng và hiệu quả.