

Chương 3. Hồi quy (Regression)

Học máy 67CS1

Mục lục

1	Bài toán hồi quy	2
1.1	Giới thiệu về Bài toán hồi quy trong học máy	2
1.2	Mô tả Bài toán Hồi quy bằng Toán học	2
1.3	Hàm Mất mát (Loss Function)	2
1.4	Các Phương pháp Hồi quy	2
1.4.1	Hồi quy tuyến tính (Linear Regression)	2
1.4.2	Hồi quy phi tuyến (Non-linear Regression)	2
1.4.3	Hồi quy Ridge và LASSO	3
1.5	Ứng Dụng của Hồi quy trong Thực tiễn	3
1.6	Kết luận	3
2	Hồi quy tuyến tính	4
2.1	Công thức toán học	4
2.2	Code Python	4
3	Hồi quy dựa trên cây	6
3.1	Giới thiệu về hồi quy dựa trên cây	6
3.2	Cấu trúc của cây hồi quy	6
3.3	Quy trình xây dựng cây hồi quy	6
3.4	Các ưu điểm của hồi quy dựa trên cây	6
3.5	Nhược điểm của hồi quy dựa trên cây	7
3.6	Kết luận	7

1 Bài toán hồi quy

1.1 Giới thiệu về Bài toán hồi quy trong học máy

Hồi quy (Regression) là một lĩnh vực quan trọng trong học máy (machine learning) và thống kê, được sử dụng để xác định mối quan hệ giữa các biến số và dự đoán giá trị của một biến phụ thuộc dựa trên các biến độc lập. Mục tiêu của bài toán hồi quy là xây dựng một hàm số $f(x)$ sao cho hàm này có thể dự đoán giá trị của một biến y từ các biến x với độ chính xác cao.

1.2 Mô tả Bài toán Hồi quy bằng Toán học

Cho một tập dữ liệu gồm n điểm dữ liệu (x_i, y_i) với $i = 1, 2, \dots, n$, trong đó:

- x_i là vector của các biến độc lập (đầu vào).
- y_i là biến phụ thuộc (đầu ra hoặc giá trị mục tiêu).

Bài toán hồi quy cố gắng tìm một hàm $f(x)$ sao cho:

$$y \approx f(x) \quad (1)$$

1.3 Hàm Mất mát (Loss Function)

Để đánh giá mức độ chính xác của mô hình hồi quy, ta sử dụng hàm mất mát (Loss Function). Một trong những hàm mất mát phổ biến nhất là hàm lỗi bình phương (Mean Squared Error – MSE):

$$L(f) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 \quad (2)$$

Mục tiêu là tìm ra một hàm số $f(x)$ sao cho giá trị của $L(f)$ được tối ưu hóa (thường là tối thiểu).

1.4 Các Phương pháp Hồi quy

Những phương pháp phổ biến trong hồi quy bao gồm:

1.4.1 Hồi quy tuyến tính (Linear Regression)

Hồi quy tuyến tính là phương pháp đơn giản nhất và phổ biến nhất trong các kỹ thuật hồi quy, biểu thị mối quan hệ tuyến tính giữa biến đầu vào và biến đầu ra. Hàm hồi quy tuyến tính có dạng:

$$f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (3)$$

Trong đó, $\beta_0, \beta_1, \dots, \beta_p$ là các tham số cần được ước lượng.

1.4.2 Hồi quy phi tuyến (Non-linear Regression)

Khi quan hệ giữa biến đầu vào và biến đầu ra không tuyến tính, ta cần sử dụng hồi quy phi tuyến. Các mô hình phi tuyến có thể phức tạp hơn và biểu diễn bằng các hàm số có dạng không tuyến tính (ví dụ như hàm mũ, lượng giác, logarit,...).

1.4.3 Hồi quy Ridge và LASSO

Đây là các biến thể của hồi quy tuyến tính có thêm các biến điều chỉnh (regularization terms) để ngăn ngừa tình trạng quá khớp (overfitting).

- **Hồi quy Ridge:**

$$L(f) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad (4)$$

- **Hồi quy LASSO (Least Absolute Shrinkage and Selection Operator):**

$$L(f) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \sum_{j=1}^p |\beta_j| \quad (5)$$

1.5 Ứng Dụng của Hồi quy trong Thực tiễn

Hồi quy được áp dụng rộng rãi trong nhiều lĩnh vực như kinh tế, sinh học, kỹ thuật, tài chính, và nhiều lĩnh vực khác. Ví dụ, trong kinh tế, hồi quy được sử dụng để dự báo giá trị cổ phiếu, trong y tế để tính toán liều lượng thuốc phù hợp dựa trên các chỉ số bệnh nhân, và trong kỹ thuật để dự đoán tuổi thọ của máy móc.

1.6 Kết luận

Hồi quy là một công cụ mạnh mẽ và linh hoạt trong học máy, giúp chúng ta dự đoán và phân tích mối quan hệ giữa các biến. Với sự phát triển của công nghệ và dữ liệu lớn, hồi quy ngày càng trở nên quan trọng và được ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau.

2 Hồi quy tuyến tính

Hồi quy tuyến tính là một phương pháp thống kê được sử dụng để mô hình hóa mối quan hệ giữa một biến phụ thuộc (thường được ký hiệu là y) và một hoặc nhiều biến độc lập (thường được ký hiệu là x). Trong trường hợp đơn giản nhất, hồi quy tuyến tính đơn giản, chỉ có một biến độc lập.

2.1 Công thức toán học

Công thức hồi quy tuyến tính đơn giản có dạng:

$$y = \beta_0 + \beta_1 x + \epsilon \quad (6)$$

- (y): Biến phụ thuộc.
- (x): Biến độc lập.
- (β_0): Hệ số chặn (intercept).
- (β_1): Hệ số góc (slope).
- (ϵ): Sai số (error term).

Trong trường hợp hồi quy tuyến tính đa biến với nhiều biến độc lập, công thức tổng quát là:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon = (x_1, x_2, \dots, x_n) : \text{Các biến độc lập.} \quad (7)$$

- ($\beta_0, \beta_1, \beta_2, \dots, \beta_n$): Các hệ số hồi quy.

2.2 Code Python

Dưới đây là một ví dụ về cách thực hiện hồi quy tuyến tính đơn giản bằng Python sử dụng thư viện `scikit-learn`:

```
1 # Import các thư viện cần thiết
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.linear_model import LinearRegression
5 from sklearn.model_selection import train_test_split
6 from sklearn.metrics import mean_squared_error, r2_score
7
8 # Tạo dữ liệu giả lập
9 np.random.seed(0)
10 X = 2 * np.random.rand(100, 1)
11 y = 4 + 3 * X + np.random.randn(100, 1)
12
13 # Chia dữ liệu thành tập huấn luyện và tập kiểm tra
14 X_train, X_test, y_train, y_test = train_test_split(X, y,
15                                                     test_size=0.2, random_state=0)
16
17 # Khởi tạo mô hình hồi quy tuyến tính
```

```

17 model = LinearRegression()
18
19 # Huấn luyện mô hình với dữ liệu huấn luyện
20 model.fit(X_train, y_train)
21
22 # Dự đoán với dữ liệu kiểm tra
23 y_pred = model.predict(X_test)
24
25 # In các hệ số hồi quy
26 print(f'Hệ số chặn (intercept): {model.intercept_}')
27 print(f'Hệ số góc (slope): {model.coef_}')
28
29 # Đánh giá mô hình
30 mse = mean_squared_error(y_test, y_pred)
31 r2 = r2_score(y_test, y_pred)
32 print(f'Mean Squared Error: {mse}')
33 print(f'R^2 Score: {r2}')
34
35 # Vẽ biểu đồ
36 plt.scatter(X_test, y_test, color='blue', label='Actual data')
37 plt.plot(X_test, y_pred, color='red', linewidth=2, label='Fitted
    line')
38 plt.xlabel('X')
39 plt.ylabel('y')
40 plt.legend()
41 plt.show()

```

Đoạn mã trên thực hiện các bước sau:

1. Tạo dữ liệu giả lập.
2. Chia dữ liệu thành tập huấn luyện và tập kiểm tra.
3. Khởi tạo mô hình hồi quy tuyến tính.
4. Huấn luyện mô hình với dữ liệu huấn luyện.
5. Dự đoán với dữ liệu kiểm tra.
6. In các hệ số hồi quy.
7. Đánh giá mô hình bằng Mean Squared Error (MSE) và R² Score.
8. Vẽ biểu đồ biểu diễn dữ liệu thực và đường hồi quy.

3 Hồi quy dựa trên cây

3.3 Hồi quy dựa trên cây. Hồi quy dựa trên cây (CART – Classification And Regression Trees) là một phương pháp phân tích dữ liệu mạnh mẽ, thường được sử dụng trong thống kê và học máy. Phương pháp này giúp chúng ta xây dựng các mô hình để dự đoán giá trị của biến mục tiêu dựa trên các biến độc lập.

3.1 Giới thiệu về hồi quy dựa trên cây

Hồi quy dựa trên cây là một kỹ thuật hình thành cây quyết định, trong đó mỗi nút trong cây đại diện cho một phép đo hoặc tiêu chí phân chia dữ liệu. Cây được xây dựng thông qua việc phân chia không gian đặc trưng thành các vùng khác nhau, sao cho các điểm dữ liệu trong mỗi vùng có giá trị mục tiêu tương đối giống nhau.

3.2 Cấu trúc của cây hồi quy

- **Nút gốc (Root Node):** Là nút đầu tiên của cây, từ đó dữ liệu bắt đầu được phân chia.
- **Nút quyết định (Decision Node):** Là các nút nội bộ phân chia dữ liệu theo các tiêu chí nhất định.
- **Nút lá (Leaf Node):** Là nút cuối cùng của cây, đại diện cho giá trị dự đoán của biến mục tiêu.

3.3 Quy trình xây dựng cây hồi quy

Quá trình xây dựng cây hồi quy có thể được tóm tắt qua các bước chính:

1. **Chọn biến và điểm phân chia:** Tại mỗi nút, xác định biến độc lập nào sẽ được sử dụng để phân chia và tại điểm nào.
2. **Phân chia dữ liệu:** Dữ liệu được phân chia thành các nhóm dựa vào biến và điểm phân chia đã chọn.
3. **Lặp lại:** Lặp lại quá trình cho đến khi đạt được một tiêu chí dừng nào đó (chẳng hạn như độ sâu tối đa của cây, số lượng mẫu tối thiểu trong nút, hoặc giá trị tối thiểu của các phân chia).
4. **Dự đoán:** Sử dụng cây hồi quy để dự đoán giá trị cho các điểm dữ liệu mới bằng cách đưa chúng qua các nút phân chia cho đến khi đến nút lá.

3.4 Các ưu điểm của hồi quy dựa trên cây

- **Dễ hiểu và minh bạch:** Cấu trúc của cây cho phép người dùng dễ dàng hiểu và giải thích mô hình.
- **Không yêu cầu giả định phân phối:** Không như một số phương pháp hồi quy khác, hồi quy cây không yêu cầu dữ liệu phải tuân thủ phân phối nhất định.

- **Có khả năng xử lý dữ liệu phi tuyến:** Cây có thể xác định các mối quan hệ phi tuyến giữa biến độc lập và mục tiêu.

3.5 Nhược điểm của hồi quy dựa trên cây

- **Quá khớp (Overfitting):** Cây có thể dễ dàng trở nên phức tạp và bị quá khớp với dữ liệu huấn luyện nếu không được kiểm soát.
- **Tính nhạy cảm với dữ liệu bất thường:** Cây hồi quy có thể bị ảnh hưởng mạnh bởi các điểm dữ liệu bất thường hay ngoại lệ.

3.6 Kết luận

Hồi quy dựa trên cây là một công cụ hữu ích trong phân tích dữ liệu và học máy. Mặc dù có một số nhược điểm, nhưng với cách tiếp cận hợp lý như cắt tỉa (pruning) và bảo vệ cây chống lại tình trạng quá khớp, nó có thể tạo ra các mô hình dự đoán mạnh mẽ và dễ hiểu.