

được mô tả trong một dòng. Mỗi ví dụ huấn luyện được ký hiệu bằng một cặp $(\mathbf{x}_i, y_i)$, trong đó $\mathbf{x}_i$ là vec tơ các đặc trưng hay thuộc tính, y_i là giá trị nhãn phân loại hay giá trị đích trong hồi quy. Như vậy $\mathbf{x}_i$ là đầu vào, còn y_i là đầu ra cần dự đoán. Trong giai đoạn huấn luyện, thuật toán được cung cấp giá trị y_i ; trong giai đoạn dự đoán, mô hình được sử dụng để dự đoán giá trị này.

Kết quả học thường được thể hiện dưới dạng một ánh xạ từ mẫu sang nhãn phân loại gọi là *mô hình học*. Mô hình này được thể hiện dưới dạng một hàm gọi là *hàm đích* (target function) có dạng $f: X \rightarrow C$, trong đó X là không gian các ví dụ và C là tập các nhãn phân loại khác nhau. Tùy vào phương pháp cụ thể, hàm đích có thể rất khác nhau. Ví dụ, hàm đích có thể là một hàm tuyến tính như trong hồi quy tuyến tính, là mô hình dạng cây trong học cây quyết định, là mạng nơ ron trong mạng nơ ron nhân tạo .v.v.

5.2. HỌC CÂY QUYẾT ĐỊNH

Sau khi làm quen với các khái niệm chung về học máy ở trên, trong phần này, ta sẽ làm quen với một kỹ thuật học máy cụ thể: *học cây quyết định*. Học cây quyết định là một trong phương pháp học máy tiêu biểu có nhiều ứng dụng trong phân loại và dự đoán. Mặc dù độ chính xác của phương pháp này không thật cao so với những phương pháp được nghiên cứu gần đây, học cây quyết định vẫn có nhiều ưu điểm như đơn giản, dễ lập trình, và cho phép biểu diễn hàm phân loại dưới dạng dễ hiểu, dễ giải thích cho con người. Phương pháp này thường được dùng như phương pháp mở đầu để minh họa cho kỹ thuật học bộ phân loại từ dữ liệu.

Phương pháp học cây quyết định được sử dụng cho việc học các hàm phân loại từ dữ liệu huấn luyện, trong đó cây quyết định được sử dụng làm biểu diễn xấp xỉ của hàm phân loại, tức là hàm có đầu ra là các giá trị rời rạc. Như đã nói ở trên, phương pháp học này thuộc loại học có giám sát.

Phần này sẽ giúp người đọc làm quen với khái niệm cây quyết định, đồng thời giới thiệu một số thuật toán học cây quyết định bao gồm ID3 và C4.5.

5.2.1. Khái niệm cây quyết định

Cây quyết định là một cấu trúc ra quyết định có dạng cây (xem hình 5.4). Cây quyết định nhận đầu vào là một bộ giá trị *thuộc tính* mô tả một đối tượng hay một tình huống và trả về một giá trị rời rạc. Mỗi bộ thuộc tính đầu vào được gọi là một *mẫu* hay một *ví dụ*, đầu ra gọi là *loại* hay *nhãn phân loại*. Thuộc tính đầu vào còn được gọi là đặc trưng và có thể nhận giá trị rời rạc hoặc liên tục. Để cho đơn giản, trước tiên ta sẽ xem xét thuộc tính rời rạc, sau đó sẽ mở rộng cho trường hợp thuộc tính nhận giá trị liên tục.


Trong các trình bày tiếp theo, tập thuộc tính đầu vào được cho dưới dạng vec tơ $\mathbf{x}$, nhãn phân loại đầu ra được ký hiệu là y , cây quyết định là hàm $f(\mathbf{x})$ trả lại giá trị y . Để tiện minh họa, trong phần này sẽ sử dụng bộ dữ liệu được cho trên hình 5.5.

Cây quyết định được biểu diễn dưới dạng một cấu trúc cây (xem ví dụ trên hình 5.4). Mỗi nút trung gian, tức là nút không phải nút lá, tương ứng với phép kiểm tra một thuộc tính.

Mỗi nhánh phía dưới của nút đó tương ứng với một giá trị của thuộc tính hay một kết quả của phép thử. Khác với nút trung gian, nút lá không chứa thuộc tính mà chứa nhãn phân loại.

Để xác định nhãn phân loại cho một ví dụ nào đó, ta cho ví dụ chuyển động từ gốc cây về phía nút lá. Tại mỗi nút, thuộc tính tương ứng với nút được kiểm tra, tùy theo giá trị của thuộc tính đó mà ví dụ được chuyển xuống nhánh tương ứng bên dưới. Quá trình này lặp lại cho đến khi ví dụ tới được nút lá và được nhận nhãn phân loại là nhãn của nút lá tương ứng.

Xét ví dụ cây quyết định trên hình 5.4 được xây dựng cho bộ dữ liệu trong hình 5.5. Cây quyết định cho phép xác định (phân loại) các buổi sáng thành có (phù hợp) và không (phù hợp) cho việc chơi tennis tùy theo thời tiết trong ngày đó. Thời tiết mỗi ngày được mô tả thông qua bốn thuộc tính: Trời, Độ ẩm, Nhiệt độ, Gió.



Hình 5.4. Một ví dụ cây quyết định cho bài toán “Chơi tennis”. Nút lá chứa nhãn phân loại “có chơi” hoặc “không chơi”. Nút trung gian chứa thuộc tính thời tiết.

Giả sử ta có ví dụ $\langle \text{Trời} = \text{nắng}, \text{Nhiệt độ} = \text{cao}, \text{Gió} = \text{mạnh}, \text{Độ ẩm} = \text{cao} \rangle$. Ví dụ sẽ được cây quyết định xếp xuống nút ngoài cùng bên trái và do vậy được xác định là “không chơi”.

Có thể thấy cách biểu diễn hàm quyết định dưới dạng cây rất trực quan, dễ hiểu, dễ giải thích lý do ra quyết định về nhãn cho một ví dụ cụ thể nào đó.

Biểu diễn tương đương dưới dạng biểu thức logic

Cây quyết định có thể biểu diễn tương đương dưới dạng các quy tắc hay biểu thức logic.

$$\text{Cây_quyết_định}(\mathbf{x}) \Leftrightarrow (P_1(\mathbf{x}) \vee P_2(\mathbf{x}) \vee \dots \vee P_n(\mathbf{x}))$$

trong đó mỗi $P_i(\mathbf{x})$ là hội các phép thử thuộc tính theo đường đi từ gốc tới nút lá có giá trị dương (true). Cụ thể, cây quyết định trên hình 4.1 có thể biểu diễn tương đương dưới dạng:

$$(\text{Trời} = \text{nắng} \wedge \text{Độ ẩm} = \text{bình_thường})$$

$$\vee (\text{Trời} = \text{u_ám})$$

$$\vee (\text{Trời} = \text{mưa} \wedge \text{Gió} = \text{yếu})$$

Hoặc biểu diễn dưới dạng các luật suy diễn Nếu ... Thì... như sau:

Nếu (Trời = nắng) và (Độ ẩm = bình thường) Thì “có chơi”

Nếu (Trời = nắng) và (Độ ẩm = cao) Thì “không chơi”

Nếu (Trời = u ám) Thì “có chơi”

Nếu (Trời = mưa) và (Gió = mạnh) Thì “không chơi”

Nếu (Trời = mưa) và (Gió = yếu) Thì “có chơi”.

Các luật dạng này rất gần gũi với cách diễn đạt của con người khi ra quyết định hay thực hiện phân loại.

5.2.2. Thuật toán học cây quyết định

Trước khi sử dụng cây quyết định, ta cần xây dựng hay “học” cây quyết định từ dữ liệu huấn luyện. Có nhiều thuật toán khác nhau được đề xuất và sử dụng để học cây quyết định từ dữ liệu, trong đó đa số dựa trên nguyên tắc chung là xây dựng cây theo kiểu tìm kiếm tham lam từ cây đơn giản tới cây phức tạp hơn. Phần này sẽ giới thiệu **thuật toán học cây ID3**, một thuật toán đơn giản nhưng có tính đại diện cho cách xây dựng cây như vậy. ID3 là viết tắt của từ Iterative Dichotomiser 3 (tạm dịch là phân chia lặp hay phân chia tuần tự). Thuật toán này do Ross Quinlan phát triển và có một phiên bản cải tiến gọi là **C4.5**.

Dữ liệu huấn luyện

Dữ liệu huấn luyện được cho dưới dạng n mẫu hay n ví dụ huấn luyện, mỗi ví dụ có dạng $(\mathbf{x}_i, y_i)$, trong đó $\mathbf{x}_i$ là véc tơ các thuộc tính và y_i là giá trị nhãn phân loại, chẳng hạn như ví dụ trong hình 5.5 với 14 ví dụ tương ứng với 14 dòng. Cột đầu tiên trong bảng chứa số thứ tự và không tham gia vào cây quyết định. Bốn cột tiếp theo chứa giá trị bốn thuộc tính. Cột ngoài cùng bên phải chứa nhãn phân loại. Đối với dữ liệu đang xét, nhãn phân loại là nhãn nhị phân, có thể nhận một trong hai giá trị “có” hoặc “không”.

Ngày	Trời	Nhiệt độ	Độ ẩm	Gió	Chơi tennis
D1	nắng	Cao	Cao	yếu	không
D2	nắng	Cao	Cao	mạnh	không
D3	u ám	Cao	Cao	yếu	có
D4	Mưa	trung bình	cao	yếu	có
D5	Mưa	thấp	bình thường	yếu	có
D6	Mưa	thấp	bình thường	mạnh	không
D7	u ám	thấp	bình thường	mạnh	có
D8	nắng	trung bình	cao	yếu	không
D9	nắng	thấp	bình thường	yếu	có

D10	mưa	trung bình	bình thường	yếu	có
D11	nắng	trung bình	bình thường	mạnh	có
D12	u ám	trung bình	cao	mạnh	có
D13	u ám	Cao	bình thường	yếu	có
D14	mưa	trung bình	cao	mạnh	không

Hình 5.5. Bộ dữ liệu huấn luyện cho bài toán phân loại “Chơi tennis”.

Thuật toán học cây ID3

Nhiệm vụ của thuật toán học là xây dựng cây quyết định phù hợp với tập dữ liệu huấn luyện, tức là cây quyết định có đầu ra giống (nhiều nhất) với nhãn phân loại cho trong tập mẫu. Trong trường hợp số thuộc tính nhỏ, việc xây dựng cây quyết định như vậy có thể thực hiện bằng cách liệt kê tất cả các cây quyết định hợp lệ và kiểm tra để chọn ra cây phù hợp với dữ liệu. Với số lượng thuộc tính lớn, số cây quyết định như vậy là rất lớn và không thể tìm kiếm theo kiểu vét cạn như vậy. Do đó, thuật toán học cây thường dựa trên nguyên tắc tham lam, xây dựng dần các nút từ trên xuống.

Quá trình xây dựng cây: Để bắt đầu, thuật toán học lựa chọn thuộc tính cho nút gốc. Thuộc tính được lựa chọn là thuộc tính cho phép *phân chia tốt nhất* các ví dụ thành những tập con, sao cho mỗi tập con càng đồng nhất càng tốt. Ở đây, đồng nhất được hiểu là các ví dụ có cùng nhãn phân loại. Sau khi lựa chọn được thuộc tính cho nút gốc, tập dữ liệu ban đầu sẽ được chia xuống các nhánh con do kết quả phép kiểm tra thuộc tính ở gốc. Với mỗi tập con dữ liệu, ta lại có một bài toán học cây dữ liệu mới và do vậy có thể lặp lại thủ tục ở trên với ít dữ liệu hơn và bớt đi một thuộc tính đã được sử dụng ở gốc.

Quá trình xây dựng cây quyết định được lặp đi lặp lại cho tới khi xảy ra những tình huống sau:

- Sau khi phân chia tại một nút, tập dữ liệu con chỉ chứa các mẫu có cùng nhãn phân loại (chẳng hạn cùng dương hoặc cùng âm). Trong trường hợp này ta dừng quá trình phân chia ở đây, tạo một nút lá và gán cho nút nhãn phân loại trùng với nhãn của các ví dụ tại nút đó. Trong ví dụ trên hình 5.4, nhánh giữa của nút gốc bao gồm các mẫu có nhãn “có” tạo thành nút lá.
- Tất cả các thuộc tính đã được sử dụng ở phía trên, trong khi tập dữ liệu con còn chứa cả nhãn dương và nhãn âm. Đây là trường hợp các ví dụ có cùng giá trị thuộc tính nhưng lại khác nhãn phân loại và xảy ra do dữ liệu huấn luyện có chứa nhiễu hoặc do các thuộc tính hiện có không cung cấp đủ thông tin để xác định đúng nhãn phân loại. Trong trường hợp này, thuật toán sẽ chọn nhãn chiếm đa số trong tập con để gán cho nút.

Thuật toán học cây quyết định được cho trên hình 5.6.

Đầu vào: Tập dữ liệu huấn luyện

Đầu ra: Cây quyết định

Khởi đầu: nút hiện thời là nút gốc chứa toàn bộ tập dữ liệu huấn luyện

a. Tại nút hiện thời n , lựa chọn thuộc tính:

- Chưa được sử dụng ở nút tổ tiên (tức là nút nằm trên đường đi từ gốc tới nút hiện thời)
- Cho phép phân chia tập dữ liệu hiện thời thành các tập con **một cách tốt nhất**

b. Với mỗi giá trị thuộc tính được chọn:

- Thêm một nút con bên dưới
- Chia các ví dụ ở nút hiện thời về các nút con theo giá trị thuộc tính được chọn

c. Lặp (đệ quy) với mỗi nút con cho tới khi:

- Tất cả các thuộc tính đã được sử dụng ở các nút phía trên, hoặc
- Tất cả ví dụ tại nút hiện thời có cùng nhãn phân loại
- Nhãn của nút được lấy theo đa số nhãn của ví dụ tại nút hiện thời

Hình 5.6. Thuật toán xây dựng cây quyết định từ dữ liệu huấn luyện

Thuật toán được lặp đệ quy qua nhiều vòng. Tại mỗi bước lặp, thuật toán tìm cách lựa chọn một thuộc tính cho phép phân chia tập dữ liệu tại nút hiện thời một cách tốt nhất. Quá trình này được tiến hành cho tới khi đạt tới nút lá, tức là khi xảy ra một trong hai tình huống như đã nhắc tới ở trên.

Lựa chọn thuộc tính tốt nhất

Một điểm quan trọng trong thuật toán xây dựng cây quyết định là lựa chọn thuộc tính tốt nhất tại mỗi nút. Trong trường hợp lý tưởng, thuộc tính lựa chọn là thuộc tính cho phép chia tập dữ liệu thành các tập con có cùng một nhãn, và do vậy chỉ cần một phép kiểm tra thuộc tính khi phân loại. Trong trường hợp nói chung, thuộc tính lựa chọn cần cho phép tạo ra những tập con có *độ đồng nhất* cao nhất. Yêu cầu đặt ra là cần có cách đo độ đồng nhất của tập dữ liệu và mức tăng độ đồng nhất khi sử dụng một thuộc tính nào đó.

Thuật toán xây dựng cây ID3 sử dụng *entropy* làm mức đo độ đồng nhất của tập dữ liệu. Trên cơ sở entropy, thuật toán tính *độ tăng thông tin* như mức tăng độ đồng nhất, từ đây xác định thuộc tính tốt nhất tại mỗi nút.


Trong trường hợp chỉ có hai nhãn phân loại, ký hiệu là + và -, entropy $H(S)$ của tập dữ liệu S được tính như sau:

$$H(S) = -p_+ \log_2 p_+ - p_- \log_2 p_-$$

trong đó p_+ và p_- là xác suất quan sát thấy nhãn phân loại + và -, được tính bằng tần suất quan sát thấy + và - trong tập dữ liệu. Trong tập dữ liệu trong bảng trên hình 5.5, với 9 nhãn dương và 5 nhãn âm, ký hiệu $[9+, 5-]$, ta có:

$$H([9+, 5-]) = -(9/14)\log_2(9/14) - (5/14)\log_2(5/14) = 0.94$$

Trên hình 5.7 là đồ thị thể hiện sự phụ thuộc của giá trị entropy H vào giá trị xác suất trong trường hợp nhãn nhị phân. Có thể nhận thấy, trong trường hợp nhãn nhị phân, entropy đạt giá trị tối đa bằng 1 khi xác suất hai nhãn bằng nhau và bằng 0.5, entropy đạt giá trị nhỏ nhất bằng 0 khi xác suất một nhãn là 1 và nhãn còn lại là 0. Nói chung, entropy càng gần 0 thì tập đối tượng càng đồng nhất.



Hình 5.7: Giá trị của entropy $H(X)$ trong trường hợp X có thể nhận một trong hai giá trị $\{0,1\}$

Trong trường hợp tổng quát với C nhãn phân loại có xác suất lần lượt là $p_1, p_2, \dots, p_C$, entropy được tính như sau:

$$H(S) = -\sum_{i=1}^C p_i \log_2 p_i$$

Giá trị cực đại của entropy khi đó sẽ bằng $\log_2 C$ khi các nhãn có xác suất như nhau và giá trị nhỏ nhất của entropy bằng 0 khi tất cả đối tượng có chung một nhãn. Tương tự trường hợp nhãn nhị phân, giá trị entropy càng nhỏ thì tập dữ liệu càng đồng nhất.

Sử dụng entropy như độ đo mức đồng nhất của tập mẫu, ta có thể đánh giá độ tốt của thuộc tính bằng cách so sánh entropy trước và sau khi tập mẫu được phân chia thành tập con theo giá trị của thuộc tính. Sự chênh lệch entropy trước và sau khi phân chia một tập dữ liệu bằng một thuộc tính nào đó được gọi là độ tăng thông tin và được định nghĩa dưới đây.

Độ tăng thông tin (Information Gain), ký hiệu IG , là chỉ số đánh giá độ tốt của thuộc tính trong việc phân chia tập dữ liệu thành những tập con đồng nhất. IG được tính dựa trên entropy theo công thức sau:

$$IG(S, A) = H(S) - \sum_{v \in \text{values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

trong đó:

S là tập dữ liệu ở nút hiện tại