

NHÓM 1

1. Khái niệm cây quyết định

Câu 1: Cây quyết định (Decision Tree)

- Cây quyết định là một cấu trúc phân loại hoặc hồi quy dạng cây, trong đó mỗi nút bên trong biểu thị một phép kiểm tra trên một thuộc tính, mỗi nhánh biểu thị kết quả của phép kiểm tra, và mỗi nút lá biểu thị nhãn kết quả.
- Cây được xây dựng bằng cách chọn thuộc tính tốt nhất để phân chia dữ liệu tại mỗi nút, thường dựa trên tiêu chí độ tăng thông tin (Information Gain - IG). Việc tìm kiếm là tham lam (greedy) từ trên xuống (top-down).
- Đầu vào: Một mẫu bao gồm các thuộc tính mô tả đối tượng hoặc tình huống.
- Đầu ra: Nhãn phân loại cho mẫu.

Câu 2: Hàm entropy

- Entropy đo lường độ hỗn loạn hoặc không chắc chắn của một tập dữ liệu. Khi tất cả các mẫu thuộc cùng một nhãn, entropy bằng 0 (tập dữ liệu đồng nhất). Ngược lại, entropy đạt giá trị cao nhất khi các mẫu được chia đều cho tất cả các nhãn.
- Entropy cho 2 nhãn (ví dụ nhãn dương và nhãn âm) được tính bằng công thức:

$$H(S) = -p^+ \log_2(p^+) - p^- \log_2(p^-)$$

Trong đó, p^+ là tỉ lệ mẫu mang nhãn dương, p^- là tỉ lệ mẫu mang nhãn âm.

- Entropy cho nhiều nhãn (khi có C nhãn) được tính như sau:

$$H(S) = - \sum_{t=1}^C p_t \log_2(p_t)$$

Trong đó, p_t là tỉ lệ mẫu mang nhãn thứ t , và C là tổng số nhãn có trong dữ liệu.

- Độ tăng thông tin (Information Gain - IG) là sự giảm entropy sau khi phân chia dữ liệu theo một thuộc tính. Nó được sử dụng để đánh giá thuộc tính nào phân chia tập dữ liệu tốt nhất. Cụ thể:

$$IG = H(S) - \sum_i \frac{|S_i|}{|S|} H(S_i)$$

Trong đó, S là tập dữ liệu ban đầu, S_i là các tập con sau khi phân chia theo thuộc tính.

- Trong thuật toán ID3, thuộc tính có IG cao nhất sẽ được chọn để phân chia dữ liệu tại mỗi nút.

Câu 3: Cắt tỉa cây (Pruning)

- Trước tiên tìm hiểu overfitting :
- Trong machine learning, tình trạng overfitting (quá khớp) xảy ra khi một mô hình học quá kỹ từ dữ liệu huấn luyện, đến mức nó không thể tổng quát tốt cho dữ liệu mới hoặc chưa thấy. Điều này có nghĩa là mô hình đã học thuộc lòng các đặc điểm cụ thể của dữ liệu huấn luyện, bao gồm cả nhiễu và các biến thể không quan trọng, thay vì học được các quy luật tổng quát. Khi một mô hình bị overfit, nó sẽ có hiệu suất rất tốt trên tập huấn luyện nhưng lại kém trên tập kiểm tra hoặc dữ liệu thực tế.
- Khi cây quyết định được xây dựng quá sâu, nó có thể dẫn đến overfitting (quá khớp), tức là mô hình khớp quá mức với dữ liệu huấn luyện nhưng không tổng quát hóa tốt cho dữ liệu mới.
- Cắt tỉa cây là kỹ thuật để giảm overfitting bằng cách loại bỏ các nhánh không cần thiết. Cụ thể:
 - + Đầu tiên, cây quyết định được xây dựng đầy đủ bằng dữ liệu huấn luyện.
 - + Sau đó, quá trình cắt tỉa bắt đầu bằng cách loại bỏ các nút không mang lại cải thiện đáng kể cho độ chính xác. Khi một nút bị tỉa, toàn bộ các nhánh con của nó bị xóa và nút trở thành một nút lá với nhãn được chọn theo đa số của các mẫu tại nút đó
 - + Việc cắt tỉa tiếp tục cho đến khi bất kỳ việc tỉa thêm nào đều dẫn đến giảm độ chính xác của cây trên tập kiểm tra. Điều này giúp cải thiện tính tổng quát của mô hình.
- Lợi ích của quá trình cắt tỉa:
 - + Giảm overfitting: Cây quá lớn có thể học quá mức từ dữ liệu huấn luyện và không hoạt động tốt trên dữ liệu kiểm tra.

- + Cải thiện khả năng tổng quát hóa: Cây quyết định nhỏ hơn và đơn giản hơn thường tổng quát tốt hơn trên các bộ dữ liệu mới.
- + Tăng hiệu quả tính toán: Cây nhỏ hơn yêu cầu ít tài nguyên hơn trong quá trình dự đoán.