



BỘ MÔN KHOA HỌC MÁY TÍNH  
[www.fit.nuce.edu.vn](http://www.fit.nuce.edu.vn)

---

# HỌC MÁY

## Lecture 5. Gaussian discriminant analysis. Naive Bayes.

# Gaussian discriminant analysis. Naive Bayes.

1. Nhắc lại về phân phối chuẩn với dữ liệu nhiều chiều
2. Mô hình Gaussian Discriminant Analysis
3. GDA và logistic regression
4. Thuật toán phân lớp Naive Bayes
5. Laplace smoothing

# 1. Nhắc lại về phân phối Gaussian với dữ liệu nhiều chiều

Phân phối Gaussian với dữ liệu nhiều chiều  $x \in \mathbb{R}^d$  ( $d$ -dimensions)  
(*multi-variate Gaussian distribution*)

**Mean vector** (kỳ vọng):  $\mu \in \mathbb{R}^d$

**Covariance matrix** (ma trận hiệp phương sai):  $\Sigma \in \mathbb{R}^{d \times d}$   
( $\Sigma$  đối xứng và là ma trận bán xác định dương)


Phân phối Gaussian có dạng:

$$p(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left( -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right).$$


“ $|\Sigma|$ ” là định thức của ma trận hiệp phương sai  $\Sigma$

Ký hiệu:  $\mathcal{N}(\mu, \Sigma)$


# 1. Nhắc lại về phân phối Gaussian với dữ liệu nhiều chiều



Gaussian with mean zero  
Covariance matrix  $\Sigma = I$



Gaussian with mean zero  
Covariance matrix  $\Sigma = 0.6I$



Gaussian with mean zero  
Covariance matrix  $\Sigma = 2I$

Biểu diễn của phân phối chuẩn trong miền dữ liệu nhiều chiều

## 2. Mô hình Gaussian Discriminant Analysis - 1

- Đối với bài toán phân lớp (classification), **x** là biến ngẫu nhiên liên tục
- Chúng ta có thể sử dụng mô hình **Gaussian Discriminant Analysis (GDA)**: dự đoán xác suất  $P(x|y)$  dựa theo phân phối chuẩn nhiều biến

$$\begin{aligned}y &\sim \text{Bernoulli}(\phi) \\x|y=0 &\sim \mathcal{N}(\mu_0, \Sigma) \\x|y=1 &\sim \mathcal{N}(\mu_1, \Sigma)\end{aligned}$$

- Viết dưới dạng phân phối:

$$\begin{aligned}p(y) &= \phi^y(1-\phi)^{1-y} \\p(x|y=0) &= \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_0)^T\Sigma^{-1}(x-\mu_0)\right) \\p(x|y=1) &= \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)\right)\end{aligned}$$

## 2. Mô hình Gaussian Discriminant Analysis- 2


- Tham số mô hình:  $\phi, \Sigma, \mu_0, \mu_1$
- $\mu_0, \mu_1$  là 2 vector trung bình của  $\mathbf{x} \mid \mathbf{y} = 0$  và  $\mathbf{x} \mid \mathbf{y} = 1$
- Hàm mất mát của mô hình: Log-likelihood

$$\begin{aligned}\ell(\phi, \mu_0, \mu_1, \Sigma) &= \log \prod_{i=1}^n p(x^{(i)}, y^{(i)}; \phi, \mu_0, \mu_1, \Sigma) \\ &= \log \prod_{i=1}^n p(x^{(i)} | y^{(i)}; \mu_0, \mu_1, \Sigma) p(y^{(i)}; \phi).\end{aligned}$$

Để cực đại hóa hàm  $\ell$  ta đưa về việc tìm tham số  $\phi, \Sigma, \mu_0, \mu_1$  của tập dữ liệu huấn luyện

$$\begin{aligned}\phi &= \frac{1}{n} \sum_{i=1}^n 1\{y^{(i)} = 1\} & \mu_1 &= \frac{\sum_{i=1}^n 1\{y^{(i)} = 1\} x^{(i)}}{\sum_{i=1}^n 1\{y^{(i)} = 1\}} \\ \mu_0 &= \frac{\sum_{i=1}^n 1\{y^{(i)} = 0\} x^{(i)}}{\sum_{i=1}^n 1\{y^{(i)} = 0\}} & \Sigma &= \frac{1}{n} \sum_{i=1}^n (x^{(i)} - \mu_{y^{(i)}})(x^{(i)} - \mu_{y^{(i)}})^T.\end{aligned}$$

## 2. Mô hình Gaussian Discriminant Analysis- 3



Dạng biểu diễn của mô hình GDA

# Thảo luận: GDA và logistic regression

- Nếu coi  $p(y = 1|x; \phi, \Sigma, \mu_0, \mu_1)$  là một hàm của  $x$ , lúc này biểu thức sẽ có dạng:

$$p(y = 1|x; \phi, \Sigma, \mu_0, \mu_1) = \frac{1}{1 + \exp(-\theta^T x)},$$

Với  $\theta$  là một xấp xỉ của  $\phi, \Sigma, \mu_0, \mu_1$

- Như vậy ta có dạng của thuật toán logistic regression – thuật toán phân cách.
- So sánh:
  - Nếu phân bố của  $p(x|y)$  có dạng **phân phối Gauss** thì GDA tốt
  - Nếu phân bố của  $p(x|y)$  **không theo phân phối Gauss** thì GDA **có thể kém hiệu quả hơn**



# Thuật toán phân lớp Naive Bayes - 1

- Trong thuật toán GDA, feature vector  $x$  là liên tục, là các vector số thực. **Nếu  $x$  là rời rạc** thì sử dụng thuật toán nào?
- Ví dụ: Bài toán phân loại email là spam hay non-spam:
- Biểu diễn email thành vector đặc trưng có số chiều bằng kích thước của từ điển.
- Nếu trong email có từ thứ  $j$  trong từ điển thì  $x_j = 1$ , ngược lại thì  $x_j = 0$

$$\begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \begin{matrix} giảm\_giá \\ đặc\_biệt \\ cảm\_ơn \\ \vdots \\ cực\_sốc \\ \vdots \\ khám\_phá \end{matrix}$$

Biểu diễn email có chứa từ giảm\_giá, cực\_sốc; không chứa từ đặc biệt, khám phá...

# Thuật toán phân lớp Naive Bayes - 2

- Giả sử vocabulary (bộ từ vựng) gồm 5000 từ,  $x \in \{0, 1\}^{5000}$
- Muốn xây dựng bộ phân lớp cần tối thiểu  $2^{(50000-1)}$  tham số - (quá nhiều tham số)
- Để mô hình hóa  $p(\mathbf{x}|y)$  ta giả sử  $x_i'$  là độc lập. Việc giả sử này gọi là **Naive Bayes** (NB) (ngây thơ). Kết quả của thuật toán là **Naive Bayes classifier**.

$$c = \operatorname{argmax}_{c \in \{1, \dots, C\}} p(c|\mathbf{x})$$

Xác suất  $p(c|\mathbf{x})$  được tính bằng cách:

$$c = \operatorname{argmax}_c p(c|\mathbf{x}) = \operatorname{argmax}_c \frac{p(\mathbf{x}|c)p(c)}{p(\mathbf{x})} = \operatorname{argmax}_c p(\mathbf{x}|c)p(c)$$

*$p(c)$  có thể được hiểu là xác suất để một điểm bất kỳ rơi vào class  $c$ .*

# Thuật toán phân lớp Naive Bayes - 3

$$c = \operatorname{argmax}_c p(c|\mathbf{x}) = \operatorname{argmax}_c \frac{p(\mathbf{x}|c)p(c)}{p(\mathbf{x})} = \operatorname{argmax}_c p(\mathbf{x}|c)p(c)$$

$p(c)$  có thể được hiểu là xác suất để một điểm bất kỳ rơi vào class  $c$ .

- Để tính  $p(\mathbf{x}|c)$ , ta dựa vào giả sử  $x_i$  độc lập với nhau:

$$p(\mathbf{x}|c) = p(x_1, x_2, \dots, x_d|c) = \prod_{i=1}^d p(x_i|c)$$

- Với 1 điểm dữ liệu  $\mathbf{x}^{(j)}$ , điểm này thuộc vào lớp:

$$c = \operatorname{argmax}_{c \in \{1, \dots, C\}} p(c) \prod_{i=1}^d p(x_i|c)$$

- Khi  $d$  lớn, xác suất về phải nhỏ. Ta sẽ lấy log về phải:

$$c = \operatorname{argmax}_{c \in \{1, \dots, C\}} \left( \log(p(c)) + \sum_{i=1}^d \log(p(x_i|c)) \right)$$

# Thuật toán phân lớp Naive Bayes - 4

## Các phân phối thường dùng trong NBC

### 1. Gaussian naive Bayes:

- Thành phần của vector đặc trưng là các biến liên tục:

Với mỗi chiều dữ liệu  $i$  và một class  $c$ ,  $x_i$  tuân theo một phân phối chuẩn có kỳ vọng  $\mu_{ci}$  và phương sai  $\sigma_{ci}^2$ :

$$p(x_i|c) = p(x_i|\mu_{ci}, \sigma_{ci}^2) = \frac{1}{\sqrt{2\pi\sigma_{ci}^2}} \exp\left(-\frac{(x_i - \mu_{ci})^2}{2\sigma_{ci}^2}\right)$$

*Tham số  $\mu_{ci}$  và phương sai  $\sigma_{ci}^2$  được xác định dựa trên các điểm trong training set thuộc và class  $c$*

# Thuật toán phân lớp Naive Bayes - 5

## Các phân phối thường dùng trong NBC

### 1. Gaussian naive Bayes:

- Thành phần của vector đặc trưng là các biến liên tục:

Với mỗi chiều dữ liệu  $i$  và một class  $c$ ,  $x_i$  tuân theo một phân phối chuẩn có kỳ vọng  $\mu_{ci}$  và phương sai  $\sigma_{ci}^2$ :

$$p(x_i|c) = p(x_i|\mu_{ci}, \sigma_{ci}^2) = \frac{1}{\sqrt{2\pi\sigma_{ci}^2}} \exp\left(-\frac{(x_i - \mu_{ci})^2}{2\sigma_{ci}^2}\right)$$

*Tham số  $\mu_{ci}$  và phương sai  $\sigma_{ci}^2$  được xác định dựa trên các điểm trong training set thuộc và class  $c$*

# Thuật toán phân lớp Naive Bayes - 6

## Các phân phối thường dùng trong NBC

### 2. Bernoulli Naive Bayes:

- Thành phần của vector đặc trưng là các biến rời rạc nhận giá trị 0 hoặc 1:
- Khi đó,  $p(x_i|c)$  được tính bằng:

$$p(x_i|c) = p(i|c)x_i + (1 - p(i|c))(1 - x_i)$$

*$p(i|c)$  có thể được hiểu là xác suất từ thứ  $i$  xuất hiện trong các văn bản của class  $c$*

# Thuật toán phân lớp Naive Bayes - 7

## Các phân phối thường dùng trong NBC

### 3. Multinomial Naive Bayes:

- Thành phần của vector đặc trưng là các biến rời rạc theo phân phối Poisson
- Giả sử bài toán phân loại văn bản với  $x$  là biểu diễn BoW.
- Giá trị của thành phần thứ  $i$  trong mỗi vector là số lần từ thứ  $i$  xuất hiện trong văn bản.
- Khi đó,  $p(x_i|c)$  tỉ lệ với tần suất từ thứ  $i$  xuất hiện trong các văn bản của class  $c$ .

$$\lambda_{ci} = p(x_i|c) = \frac{N_{ci}}{N_c}$$

- $N_{ci}$  là tổng số lần từ thứ  $i$  xuất hiện trong các văn bản của class  $c$ .
- $N_c$  là tổng số từ (kể cả lặp) xuất hiện trong class  $c$ .

## 5. Laplace smoothing

$$\lambda_{ci} = p(x_i|c) = \frac{N_{ci}}{N_c}$$

Nếu có 1 từ chưa bao giờ xuất hiện trong class  $c$  thì xác suất về phải công thức sau sẽ = 0

$$c = \operatorname{argmax}_{c \in \{1, \dots, C\}} p(c) \prod_{i=1}^d p(x_i|c)$$

- Để giải quyết việc này, một kỹ thuật được gọi là Laplace smoothing được áp dụng:

$$\hat{\lambda}_{ci} = \frac{N_{ci} + \alpha}{N_c + d\alpha}$$

- $\alpha$  là một số dương, thường bằng 1. Mẫu số được cộng với  $d\alpha$  để đảm bảo tổng xác suất  $\sum_{i=1}^d \hat{\lambda}_{ci} = 1$ . Như vậy, mỗi class  $c$  sẽ được mô tả bởi một bộ các số dương có tổng bằng 1:  $\hat{\lambda}_c = \{\hat{\lambda}_{c1}, \dots, \hat{\lambda}_{cd}\}$ .



# Ví dụ